时空数据表示与预处理

定义与对象

第2讲：定义、数学表示与方法体系

数据表示 → 质量诊断 → 方法选择 → 验证

方法与符号

从普通数据的基本表示出发，扩展到轨迹、事件、格网与网络。

算例 / 解释

学习目标：能够定义数据对象，选择预处理方法，并解释处理假设。

高宇岑 · 软件学院

课程成绩评定

课堂表现 15%

概念理解与课堂互动参与

课堂作业 35%

共3次，安排在本课程第2、4、6周。

期末项目 50%

每队4人；若全班人数不能被4整除，最后一队另行安排。

总评 = 课堂表现×15% + 课堂作业×35% + 期末项目×50%

依据：课程教学大纲第5节 2026年6月29日

本讲知识结构与学习要求

层次	核心概念	需要掌握
表示	样本、特征、数据集、目标变量	读懂向量与矩阵记号
体系	清洗、集成、变换、约简	区分方法所属类别
方法	KNN、PCA、匹配与轨迹简化	能写出公式并完成小算例
扩展	时空观测、轨迹与约束	说明普通方法需要怎样调整
实践	处理日志、验证与Python	区分定义、示意和实际实现

讲授顺序：定义 → 公式 → 方法条件 → 算例 → 时空扩展。

数据对象、观测与属性

定义与对象

数据对象：研究中的实体或分析单位；
观测：在给定条件下取得的记录。

$$a_j : \mathcal{O} \to \mathcal{X}_j$$

方法与符号

属性函数a_j将对象映射到第j个属性域；
取值可以是数值或类别。

算例 / 解释

对象：学生；
观测：某学生本学期表现。
属性：出勤次数、作业成绩。

数据样本与特征向量的定义

定义与对象

本讲采用机器学习惯例：单个样本是一个分析单位的特征表示。

$$x_i = (x_{i1}, \ldots, x_{id}) \in \mathcal{X}_1 \times \ldots \times \mathcal{X}_d$$

方法与符号

i是样本索引；j是特征索引；d是特征数。

算例 / 解释

x_1=(12, 85, “软件工程”)

表示一个样本的三个特征。

适用条件与边界

统计学中的“样本”也常指整组观测；本讲单条称“样本”，整组称“数据集”。

数据集与设计矩阵

定义与对象

数据集是带索引的观测集合；数值特征表通常组织为矩阵。

$$D = (x_1, \ldots, x_n),$$
$$X = [x_{ij}] \in \mathbb{R}^{n \times d}$$

方法与符号

n行对应样本，d列对应特征。

算例 / 解释

X = [(12,85); (10,70); (5,40)]

这里n=3，d=2。

属性类型与测量尺度

类型	允许的解释	例子
标称	相同或不同；不具有内在顺序	站点编号、学院
顺序	可排序；间隔未必相等	满意度等级
区间	差值有意义；零点非绝对	摄氏温度
比率	有有意义的零点，允许比值解释	长度、持续时间

离散/连续描述取值结构；标称/顺序/区间/比率描述测量尺度，两种分类不相同。

常见数据结构及其数学表示

结构	数学对象	时空例子
记录型数据	$X \in \mathbb{R}^{n \times d}$（数值编码后）	站点时段特征表
序列型数据	$S = ((t_k, z_k))$，按时间有序	传感器序列、轨迹
图结构数据	$G = (V, E)$，可配邻接矩阵A	道路网、站点流动网
多维数组	$Z \in \mathbb{R}^{T \times N \times c}$	时间×站点×通道

序列可能不等长；转成固定维度矩阵需要额外的对齐、聚合或特征提取。

样本间的距离：Minkowski度量

定义与对象

距离用于描述数值特征空间中的差异。

$$d_p(x,z) = (\Sigma_j |x_j - z_j|^p)^{1/p}, p \geq 1$$

方法与符号

p=1为曼哈顿距离，p=2为欧氏距离，p=∞为切比雪夫距离。

适用条件与边界

特征单位和缩放会改变距离；“相似”需要任务语义支持。

算例 / 解释

x=(1,2)，z=(4,6)。

d_1=7；d_2=5。

数据质量：从概念到可测指标

定义与对象

完整性、一致性、唯一性、有效性是不同的质量维度。

$$r_{miss} = 1 - (\Sigma_i \Sigma_j M_{ij}) / (nd)$$

方法与符号

M_{ij}=1表示该单元格已观测，否则为0；约束违反率和重复率须另行定义。

适用条件与边界

这些指标可诊断形式质量，不能单独证明数据准确或代表性充分。

算例 / 解释

3×2的表缺1格：

r_miss=1/6≈16.7%。

数据预处理技术体系

类别	主要任务	代表技术
数据清洗	诊断并处理质量问题	缺失填补、去重、平滑、异常与约束检查
数据集成	整合多源记录和语义	模式映射、实体对齐、单位统一
数据变换	得到适合任务的表示	缩放、编码、离散化、聚合
数据约简	降低规模或表示复杂度	特征选择、投影降维、采样

这是本课采用的组织方式；不同教材的分类边界可有差异。缩放属于变换，不等同于清洗。

数据清洗：问题—检测—处理

质量问题	诊断方法	可选处理
缺失	缺失掩码、缺失率、分组模式	删除、统计填补、近邻或模型填补
噪声	波动、残差、重复测量比较	分箱平滑、均值/中值滤波、回归拟合
异常	规则、统计、距离/密度与模型评分	标记核查、隔离、修复或有据删除
重复	业务键、精确匹配、实体匹配	合并、保留代表记录与来源
不一致	类型、范围、单位、逻辑约束	解析转换、统一单位、冲突核查

检测与处理是两个步骤；方法选择取决于数据类型、任务、原因与可用证据。

缺失值处理：方法家族与条件

方法	基本做法	主要条件 / 代价
删除	删除缺失行或高缺失率列	损失信息；可能改变样本组成
单变量填补	均值、中位数、众数或常量	只利用本列；分布与关联可能失真
多变量填补	KNN、回归或迭代预测	依赖其他特征及模型假设
序列填补	前向保持、插值或时序模型	需要排序；区分实时和事后任务

保留缺失指示变量。填补不是恢复事实，也不自动消除缺失机制导致的偏差。

均值与中位数填补

定义与对象

用训练数据中该列已观测值的统计量估计缺失单元。

$$\hat{x}_{ij} = (1 / |O_j|) \Sigma_{k \in O_j} x_{kj}$$

方法与符号

O_j为训练集中第j列已观测样本的索引集合；中位数填补用median替代均值。

算例 / 解释

2、3、4、100、NA。

均值27.25；中位数3.5。

适用条件与边界

整列缺失时无法由本列估计；均值对极端值敏感，两种方法都可能削弱变异。

KNN填补①：把缺失值估计转为近邻问题

定义与对象

在其他已观测特征上寻找相似样本，用近邻的已知值估计缺失特征。

$$d(i,k)=\|x_{i,obs}-x_{k,obs}\|_2$$

方法与符号

本页假设比较样本采用相同已观测特征；步骤：选特征与尺度 → 算距离 → 选K邻居 → 加权。

算例 / 解释

缺失的是B列。

本例只按已观测A列比较：

$d(i,k)=|A_i-A_k|$。

适用条件与边界

多维缺失需定义可比较维度与距离；软件默认缺失距离可能不同，不能把NA当0。

KNN填补②：先计算距离并选择近邻

记录	已观测A / 待填补B	到查询记录的距离
查询q	A=1，B=NA	不把自身作为邻居
r_1	A=0，B=10	$\|1-0\|=1$
r_2	A=2，B=14	$\|1-2\|=1$
r_3	A=6，B=40	$\|1-6\|=5$

取K=2，应选择哪两条？本例距离仅用A列；所有数值为教学构造。

KNN填补③：填补结果与K的影响

定义与对象

近邻必须具有待填补特征的有效值；等权时取这些值的平均。

$$\hat{B}_q=(1/K)\Sigma_{k\in N_q}B_k$$

方法与符号

K=2选择r_1、r_2：$\hat{B}$=(10+14)/2=12。若K=3，$\hat{B}$=(10+14+40)/3≈21.33。

算例 / 解释

同一查询：

K=2 → 12；

K=3 → 21.33。

适用条件与边界

K改变局部程度；尺度、邻居和权重都会影响结果。以验证数据评估，不根据测试真值挑K。

缺失标记与填补的不确定性

定义与对象

保留“原本缺失”的信息，并评估填补对分布与结论的影响。

$$z_{ij} = 1 - M_{ij}$$

方法与符号

可将z作为附加特征或审计字段；检查填补前后均值、方差和下游结论。

适用条件与边界

单次填补把估计当成固定值；不能声称它保留了全部统计不确定性。

算例 / 解释

2、3、4、5：均值3.5。

补3.5后均值不变。

总体方差1.25→1.00。

噪声处理：平滑与信号保留

定义与对象

观测可写成信号与误差之和；平滑利用局部结构抑制波动。

$$z_t = s_t + \varepsilon_t;$$

$$\tilde{z}_t = (1/w) \sum_{h=0}^{w-1} Z_{t-h}$$

方法与符号

t为离散采样索引，w为正整数窗口长度；本式为后向均值，也可用中值、分箱或回归平滑。

适用条件与边界

窗口过大会抹去真实突变；实时任务不能用尚未到达的未来值。

算例 / 解释

后向窗口：10、11、50。

均值23.67；中位数11。

异常检测：从规则到模型

方法类	异常判据	例子与边界
规则约束	违反允许域或业务关系	负时长、不合理速度
单变量统计	偏离位置与离散程度	Z-score、IQR；依赖分布形状
距离 / 密度	远离邻居或局部密度偏低	KNN距离、LOF；依赖尺度
模型评分	模型给出较高异常分数	Isolation Forest等；需校准阈值

异常点是“需要解释的偏离”；可能是测量错误，也可能是真实稀有事件。本讲详讲规则、Z-score和IQR。

规则清洗：有效域与逻辑约束

定义与对象

将字段要求写成可检验谓词，识别违反规则的记录。

$$C(r_i) = \Lambda_{\ell=1}^{m} c_\ell(r_i)$$

方法与符号

范围约束、类型约束、跨字段逻辑约束分别检查。

适用条件与边界

规则是任务约定；违反约束不必然说明哪一个字段需要改成什么值。

算例 / 解释

百分制成绩：0≤score≤100。

骑行：end_time≥start_time。

Z-score异常规则

定义与对象

以参考数据的均值和标准差衡量单变量偏离程度。

$$z_i = (x_i - \mu) / \sigma;\ |z_i| > \tau$$

方法与符号

μ、σ从参考数据估计，σ>0；常见启发式τ=3，不能无条件解释为固定误报率。

适用条件与边界

近似对称单峰分布更易解释；偏态、重尾和污染会影响均值与标准差。

算例 / 解释

μ=50，σ=5，x=68。

z=3.6。

若τ=3则标为候选异常。

IQR异常规则与计算

定义与对象

用上下四分位数构造稳健的候选异常边界。

$$IQR = Q_3 - Q_1;$$

$$[L,U] = [Q_1 - 1.5IQR,\ Q_3 + 1.5IQR]$$

方法与符号

边界外先标记；无正态分布要求。分位数算法不同，小样本结果可能略有差别。

适用条件与边界

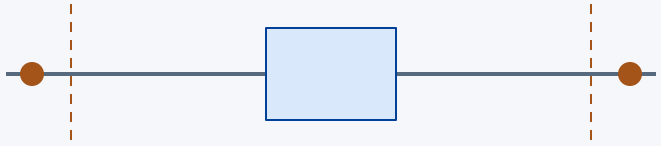
本例直接给定分位数；1.5是常用规则系数，非普适的错误判决标准。

算例 / 解释

给定$Q_1=10$、$Q_3=20$。

IQR=10，L=−5，U=35。

−8和38位于边界之外。



边界示意；位置按数值线性映射

异常处理：评分、判决与修复

定义与对象

异常检测产生分数或标志，处理动作还需结合证据与任务。

$$\mathrm{flag}_i = 1[s(x_i) > \tau]$$

方法与符号

标记 → 核查 → 隔离或修复 → 记录依据；s是约定为越大越异常的评分。

适用条件与边界

缩尾/截断会改变极端观测；研究极端事件时，删除可能破坏研究对象。

算例 / 解释

成绩850超出百分制范围。

出勤少但成绩98可能真实。

数值缩放：方法与区别

方法	公式	用途 / 条件
Min-Max	$(x-\min)/(\max-\min)$	缩放参考范围；极端值影响范围
Z-score	$(x-\mu)/\sigma$	中心化与尺度统一；不改变分布形状
稳健缩放	$(x-\text{median})/\text{IQR}$	用分位数减弱极端值对尺度估计的影响
向量归一化	$x / \|\|x\|\|_2$	按样本归一长度；与按列缩放不同

按列缩放和按行归一化需要区分。σ、IQR或极差为0时必须单独处理。

Min-Max缩放：定义与外推

定义与对象

对第j列使用训练参考最小值a_j与最大值b_j作线性缩放。

$$x'_{ij} = (x_{ij} - a_j) / (b_j - a_j)$$

方法与符号

$b_j > a_j$；若需目标区间[L,U]，再乘(U−L)并加L。

算例 / 解释

a=10，b=30。

x=20 → 0.5。

新值40 → 1.5。

适用条件与边界

训练范围内映至[0,1]；新数据可越界。裁剪是额外决策，会丢失越界幅度。

标准化与稳健缩放

定义与对象

标准化调整位置和尺度；稳健缩放改用中位数与四分位距。

$$z_{ij} = (x_{ij} - \mu_j)/\sigma_j;$$
$$r_{ij} = (x_{ij} - \text{median}_j)/\text{IQR}_j$$

方法与符号

本课$\sigma^2=(1/n)\Sigma(x-\mu)^2$，与常见StandardScaler约定一致；公式不保证高斯化。

适用条件与边界

只用训练集拟合参数；标准化不是异常点删除，也不等于正态分布变换。

算例 / 解释

μ=20，σ=5，x=30 → z=2。

median=20，IQR=10 → r=1。

类别编码：独热表示

定义与对象

对具有K个类别的标称属性，用K维指示向量表示类别身份。

$$e(c)_k = 1[c = c_k],\ k=1,\ldots,K$$

方法与符号

完整独热表示中每行恰有一个1；顺序属性可用顺序编码，
但间隔解释需另议。

适用条件与边界

类别多会扩大维度；未知类别处理和是否丢弃一列取决于模型与实现。

算例 / 解释

软件→(1,0,0)。
机械→(0,1,0)。
建筑→(0,0,1)。

离散化：将连续值映射到区间

定义与对象

用一组边界将连续属性划为若干箱，输出箱号或独热表示。

$$b_k = a + k(b-a)/K,\ k=0,\ldots,K$$

方法与符号

等宽：区间宽度相同；等频：按分位数设边界，使各箱样本数尽量接近。

适用条件与边界

离散化丢失箱内差异；重复值可能使等频箱无法恰好等量。

算例 / 解释

[0,100]分5箱，宽度20。

[0,20)、[20,40)...

最后一箱包含100。

聚合：从明细记录到分组统计

定义与对象

按分组映射g将记录划入组，计算计数、和、均值等统计量。

$$N_k = \Sigma_i \, 1[g(r_i)=k]$$

方法与符号

统计单位与窗口须明确；N_k是记录计数，不一定等于人数、设备数或事件数。

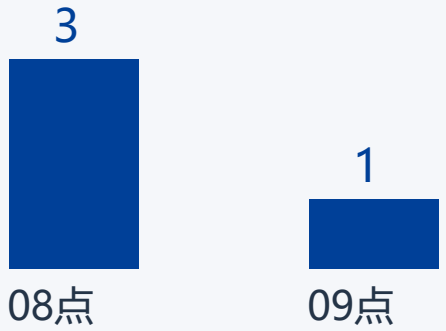
适用条件与边界

聚合会压缩细节；小时总量相同不保证小时内峰值相同。

算例 / 解释

A站借车事件：08:05、08:10、08:45、09:10。

小时计数3、1；全天4。



PCA①：主成分与最大方差方向

定义与对象

PCA寻找一组正交方向，将数值特征投影到较低维空间。

$$w_1 = \operatorname{argmax}_{\|w\|_2=1} w^T S w$$

方法与符号

先中心化$X_c = X - \mu$，再计算$S = X_c^T X_c/(n-1)$；主方向是S最大特征值对应的单位特征向量。

算例 / 解释

输入n×d，选择k<d。

输出$Z = X_c W$，

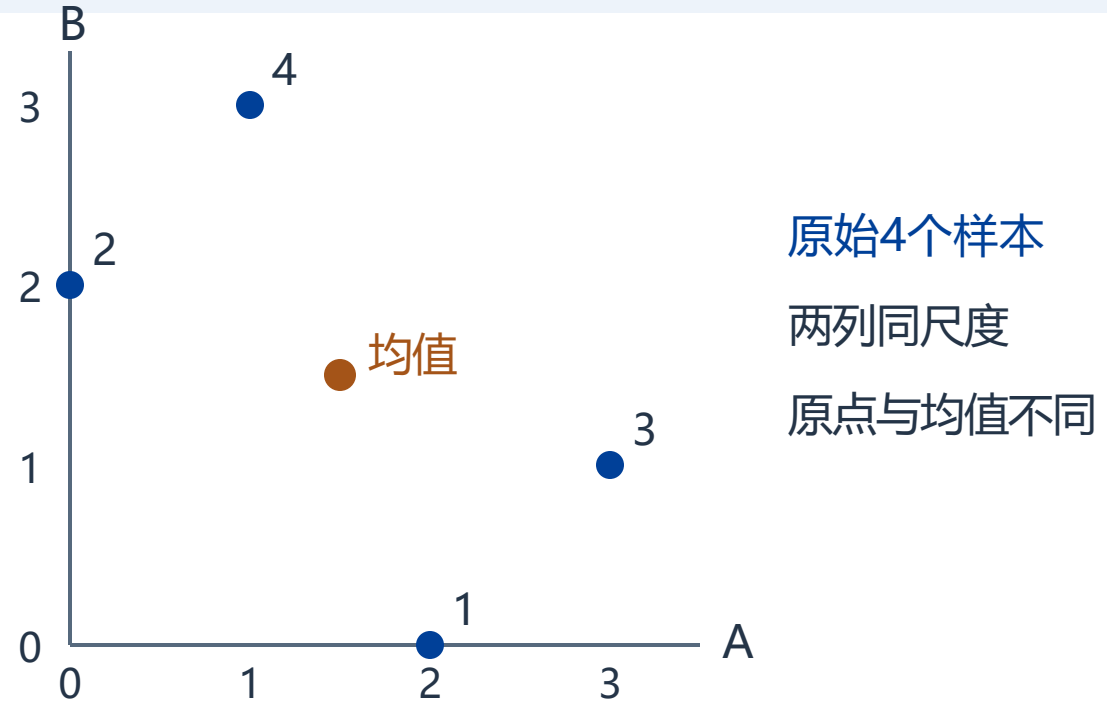
W的各列相互正交。

适用条件与边界

本讲推演二维到一维；PCA按方差而非标签选方向。求解器的数值实现不展开。

PCA②：中心化与协方差矩阵

$$\mu=(1.5,1.5);\ S=X_c^{T}\,X_c/(n-1)$$



本例两列视为同尺度；一般应先依据任务决定是否缩放。S使用n−1分母。

计算步骤与结果

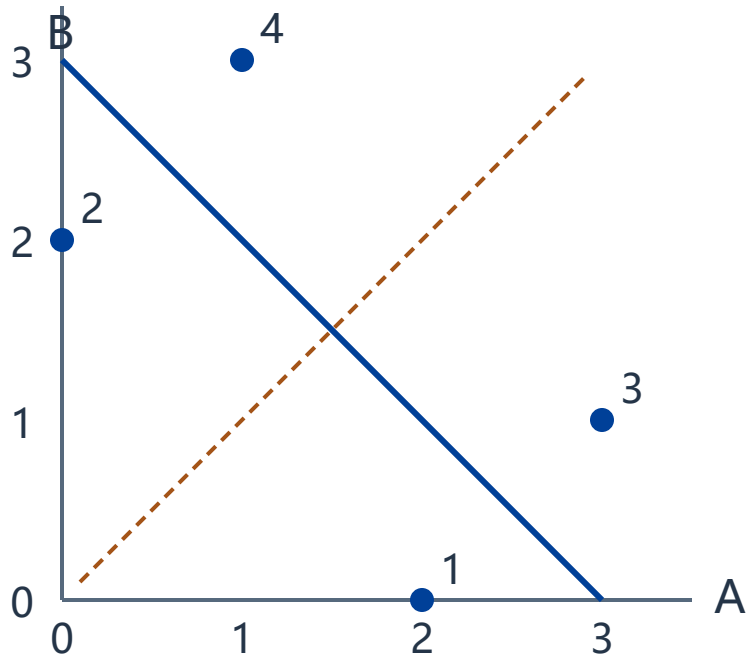
教学数据：
(2,0)、(0,2)、(3,1)、(1,3)

$S = [(5/3,-1); (-1,5/3)]$

负协方差表示两列的线性变化倾向相反。

PCA③：特征方向与解释方差

$$S\,w_j=\lambda_j\,w_j;\ \eta_1=\lambda_1/(\lambda_1+\lambda_2)$$



第一主轴 w_1

沿负斜率方向

第二主轴 w_2

两轴相互正交

计算步骤与结果

$\lambda_1=8/3$，$\lambda_2=2/3$

$w_1=(1,-1)/\sqrt{2}$

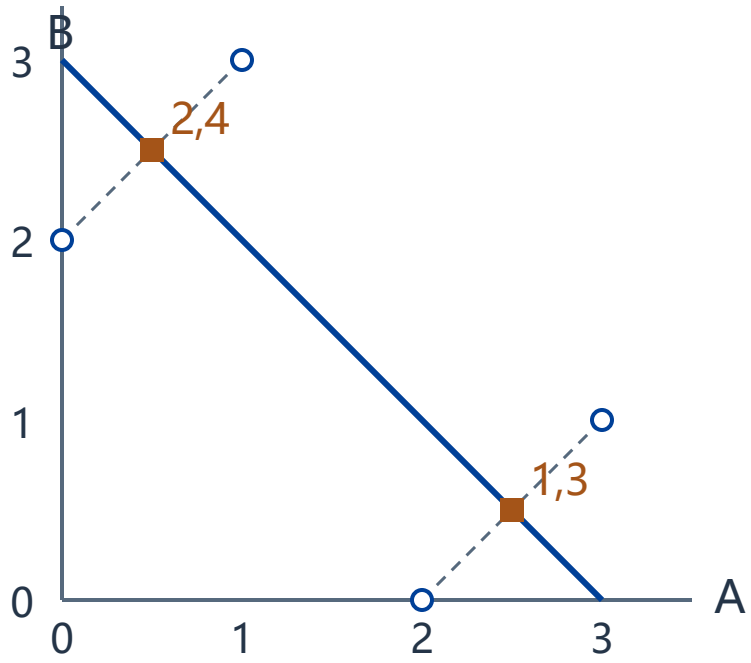
保留第一主成分：$\eta_1=80\%$。

方向正负翻转不改变所代表的轴。

解释方差80%不是预测准确率80%；方差大的方向未必是某任务最有用的方向。

PCA④：投影、重构与信息损失

$$Z = X_c\, w_1;\ \hat{X} = \mu + Z\, w_1^{T}$$



空心圆：原样本

方块：重构位置

虚线：投影残差

误差平方和 = 2

计算步骤与结果

一维分数：
$(\sqrt{2}, -\sqrt{2}, \sqrt{2}, -\sqrt{2})$

重构后仅有两种位置：
(2.5,0.5)、(0.5,2.5)

总平方重构误差为2。

降维保留主要变化，也会合并原先不同的样本；新数据必须沿用训练时的均值和主轴。

综合算例：先填补，再缩放

定义与对象

固定一个训练数据列，逐步计算处理结果与拟合参数。

$$X = (10,20,\mathrm{NA},30);\ \mu_{obs}=20$$

方法与符号

均值填补后(10,20,20,30)；用a=10、b=30缩放，得到(0,0.5,0.5,1)。

适用条件与边界

这只是训练处理示例；NA不当作0，填补列与原始列/标志分别保存。

算例 / 解释

缺失标志：(0,0,1,0)。

新值40使用相同a、b，结果1.5。

一份GPS记录，怎样变成可用轨迹？

前半讲处理单条样本的属性。现在，同一对象的记录还要按时间连接。

一条GPS记录

$r_i = (o_i, t_i, x_i, y_i)$

o_i 是对象编号，t_i 是观测时刻。
(x_i, y_i) 是局部平面坐标，单位为米。

同一对象的轨迹

把同一对象的记录按 t_i 排列，检查相邻观测能否合理连接。

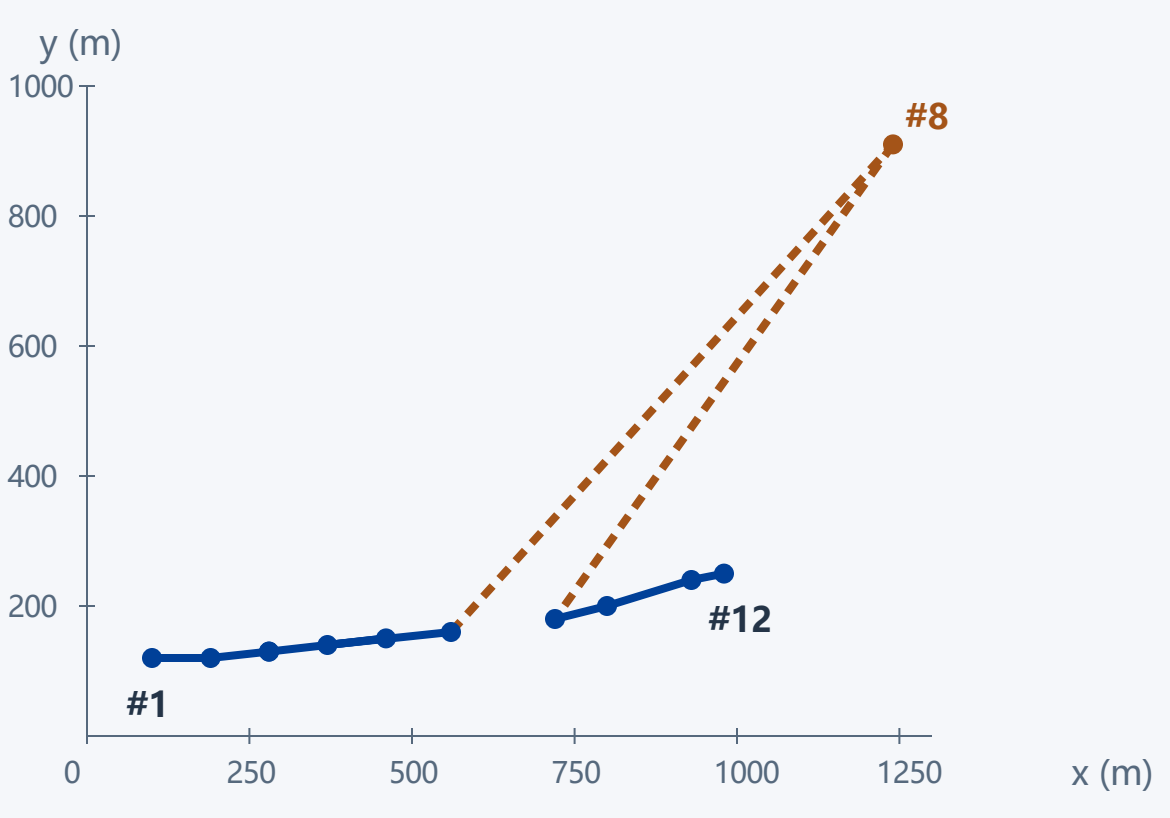
本例依次做四步：
排序 → 去重 → 跳点检查 → 分段。

本例从12条GPS记录出发，最后得到10个保留观测点和2个连续片段。

原始输入 | 12条GPS记录

同一辆车 bike-07。表按CSV文件顺序，ID为原始行号。坐标单位为米。

ID	观测时间	x (m)	y (m)	备注
1	08:00:00	100	120	
2	08:00:30	190	120	
3	08:01:00	280	130	
4	**08:01:00**	**280**	**130**	**重复观测**
5	08:02:00	460	150	
6	**08:01:30**	**370**	**140**	**时间乱序**
7	08:02:30	560	160	
8	**08:03:00**	**1240**	**910**	**可疑位置**
9	08:03:30	720	180	
10	08:04:00	800	200	
11	08:07:00	930	240	
12	08:07:30	980	250	



先找时间乱序和重复行。图上的橙色连线提示还有一次可疑位移。

判别轨迹前，先读懂时间与位置

处理对象仍是 bike-07。后面的距离和速度都以这些字段为依据。

时间 t_i

记录的观测时刻。文件中的前后顺序可能和观测先后不同。

#5 的观测是 08:02:00。
#6 的观测是 08:01:30。

位置 $p_i = (x_i, y_i)$

坐标是同一局部平面中的米制位置。

两点距离 $d(p_i,p_j) = \sqrt{(\Delta x^2 + \Delta y^2)}$。例如 #1 → #2 相距 90 m。

先用时间确定谁与谁相邻，再用位置检查这次移动是否合理。

第1步 | 按观测时间排序

按（对象编号，观测时刻）升序排列。时间相同的行暂按原有顺序保留。

ID	观测时间	x (m)	y (m)	备注
1	08:00:00	100	120	
2	08:00:30	190	120	
3	08:01:00	280	130	
4	**08:01:00**	**280**	**130**	**同一时刻**
6	**08:01:30**	**370**	**140**	**移到 #5 前**
5	**08:02:00**	**460**	**150**	**移到 #6 后**
7	08:02:30	560	160	
8	08:03:00	1240	910	
9	08:03:30	720	180	
10	08:04:00	800	200	
11	08:07:00	930	240	
12	08:07:30	980	250	

只改顺序

排序前：… #3、#4、#5、#6、#7 …

排序后：… #3、#4、#6、#5、#7 …

保留12行。#3 和 #4 还在，下一步检查是否属于同一条观测。

排序解决的是观测先后。结果仍有12条。

第2步 | 删除完全重复的观测

去重键为（对象编号，观测时刻，x，y）。四项都相同时只保留首次出现。

ID	观测时间	x (m)	y (m)	备注
1	08:00:00	100	120	
2	08:00:30	190	120	
3	**08:01:00**	**280**	**130**	**保留首次**
6	08:01:30	370	140	
5	08:02:00	460	150	
7	08:02:30	560	160	
8	08:03:00	1240	910	
9	08:03:30	720	180	
10	08:04:00	800	200	
11	08:07:00	930	240	
12	08:07:30	980	250	

为什么删除 #4?

#3 与 #4 都属于 bike-07，观测时间同为 08:01:00，坐标同为 (280, 130)。

保留 #3，删除 #4。若同一时刻出现两个不同位置，应另行标记或核查。

12 → 11。用这11条来计算相邻观测的速度。

第3步｜先判断 #8 是否像跳点

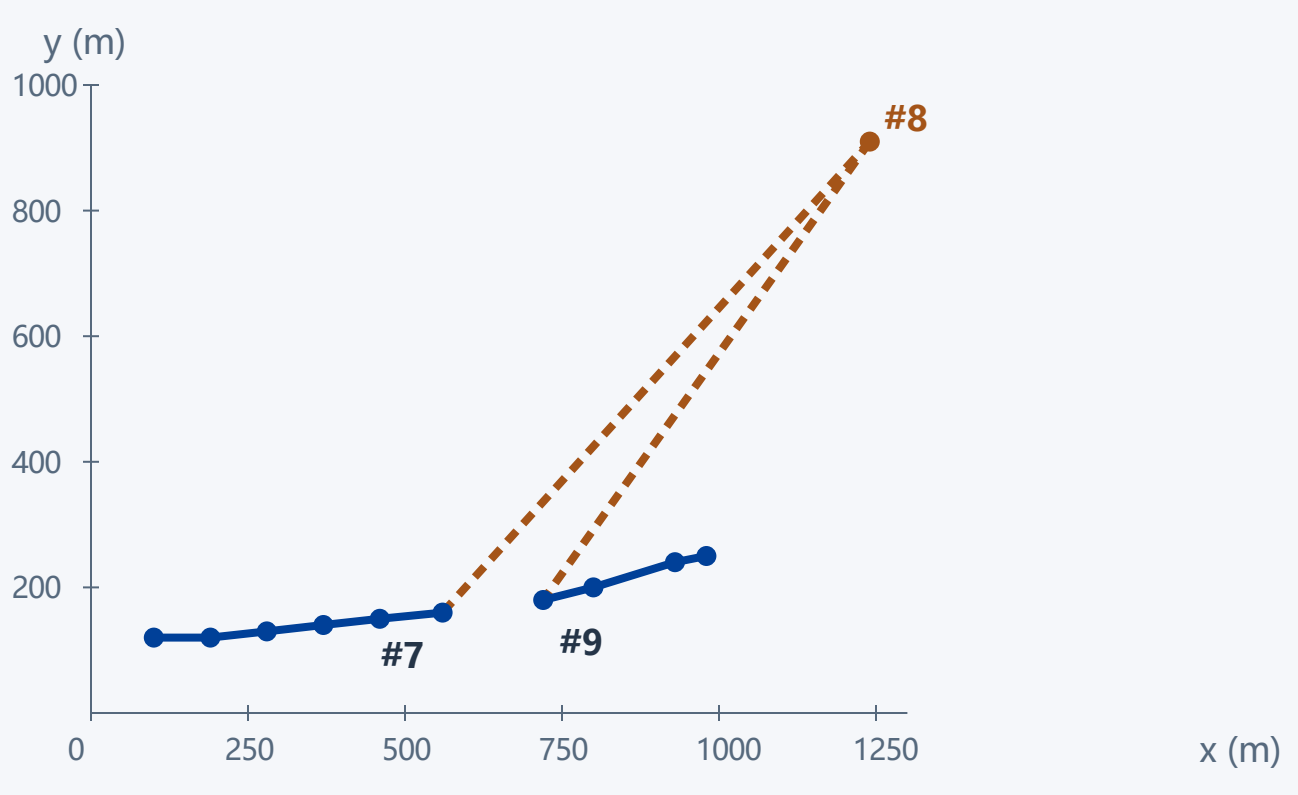
排序、去重后，#7 → #8 → #9 的两个观测间隔都是30秒。

ID	观测时间	x (m)	y (m)
#7	08:02:30	560	160
#8	**08:03:00**	**1240**	**910**
#9	08:03:30	720	180

用速度检查移动是否合理

$$v = \sqrt{(\Delta x^2 + \Delta y^2)} / \Delta t$$

本例速度上限为 12 m/s。



先算进入 #8 的速度，再看移除 #8 后，#7 → #9 是否合理。

第3步 | 剔除跳点 #8

速度用位移除以观测时间差。阈值 12 m/s 是本例设定。

连接	位移	时间差	速度	含义
#7 → #8	**1012.4 m**	**30 s**	**33.75 m/s**	**进入 #8 时超限**
#8 → #9	**896.3 m**	**30 s**	**29.88 m/s**	**离开 #8 时也超限**
#7 → #9	161.2 m	60 s	2.69 m/s	跳过 #8 后速度合理

脚本怎样做

逐条检查当前点与最后一个保留点。#8 超限后，继续用 #7 检查 #9。

11 → 10。#8 剔除，#9 保留。

第4步｜长时间没有观测，在哪里断开?

清洗后有10个点。相邻观测间隔超过 120 s 时，从下一个观测起另开一段。

相邻观测	起始时刻	结束时刻	间隔	处理
#7 → #9	08:02:30	08:03:30	60 s	保持连接
#9 → #10	08:03:30	08:04:00	30 s	保持连接
#10 → #11	**08:04:00**	**08:07:00**	**180 s**	**分段**
#11 → #12	08:07:00	08:07:30	30 s	保持连接

180 s > 120 s。把 #10 和 #11 分到不同片段，记录条数仍为10。

对照｜如果对这段空档做线性插值

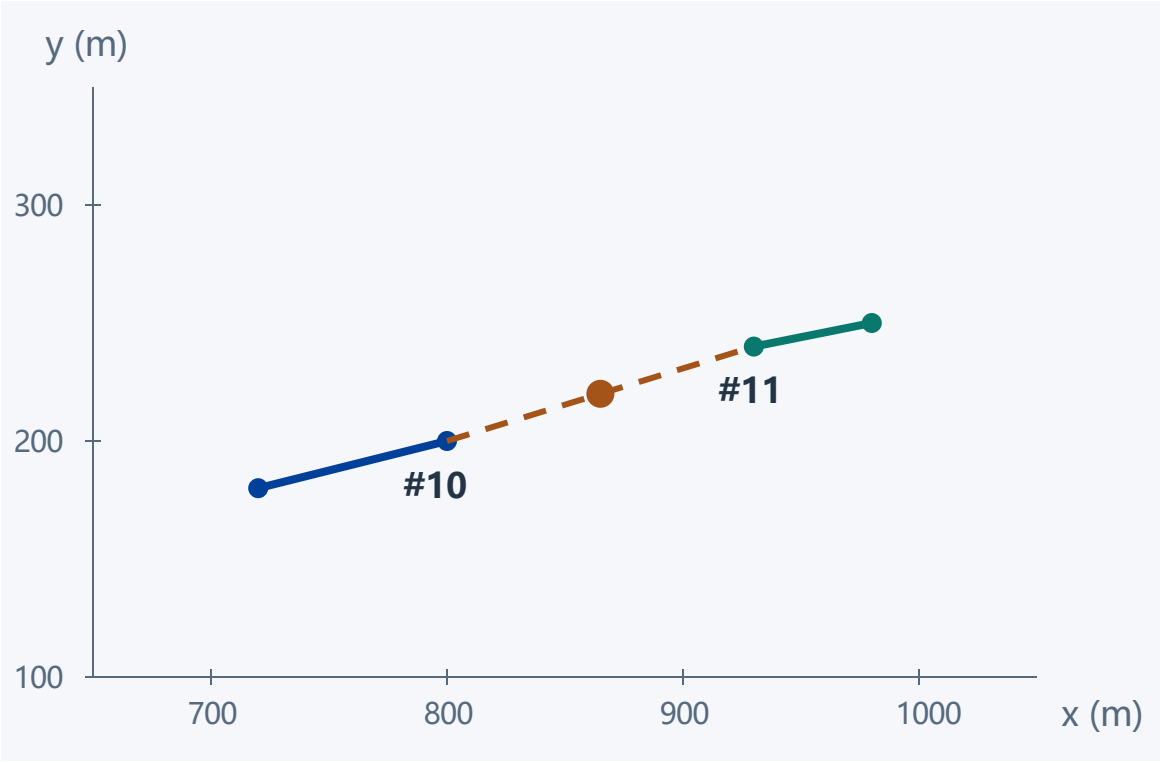
沿用 #10 和 #11 两端观测。虚线与橙点表示一种估计。

估计 08:05:30 的位置

#10 08:04:00 → (800, 200)

#11 08:07:00 → (930, 240)

时间正好在中间，线性估计取两端坐标均值，得到 (865, 220)。



本例的分段规则已触发，估计点只用于对照，不写入清洗结果。

清洗结果 | 10个点，2个连续片段

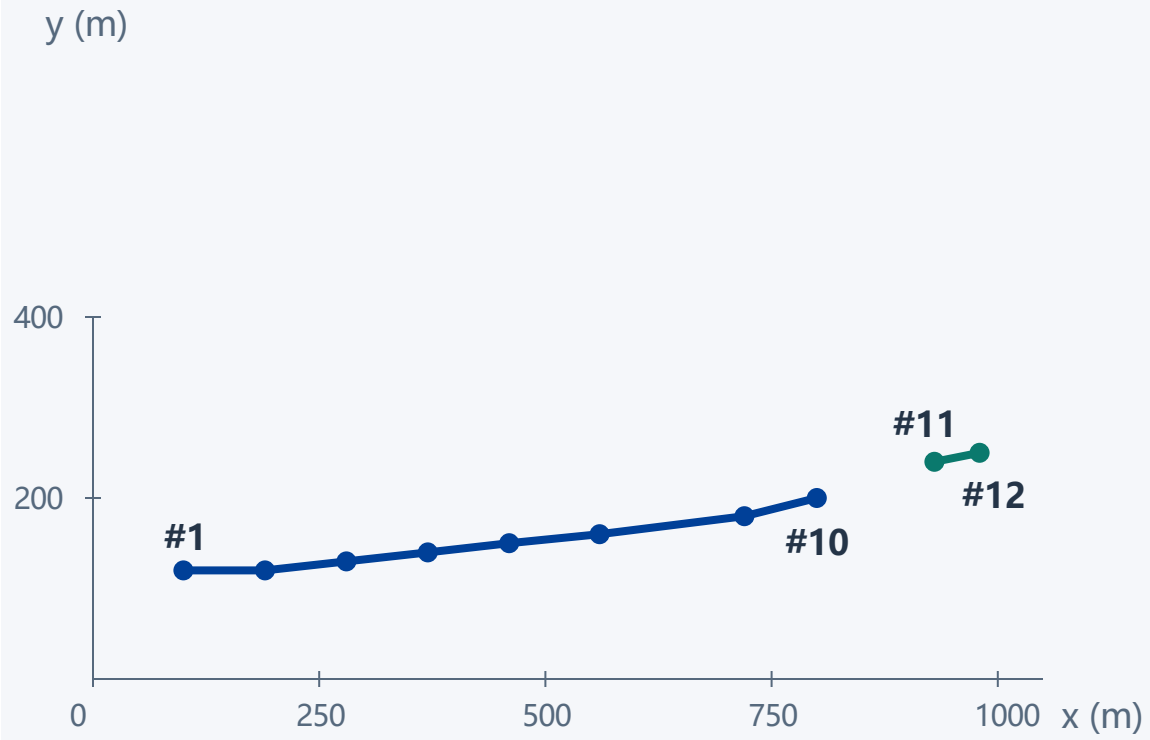
剔除 #4 和 #8 后，按时间间隔把剩余观测划分为两个片段。

两段轨迹的记录清单

片段1 · 8点 · 08:00:00–08:04:00
#1 #2 #3 #6 #5 #7 #9 #10

片段2 · 2点 · 08:07:00–08:07:30
#11 #12

#10 与 #11 之间留空。

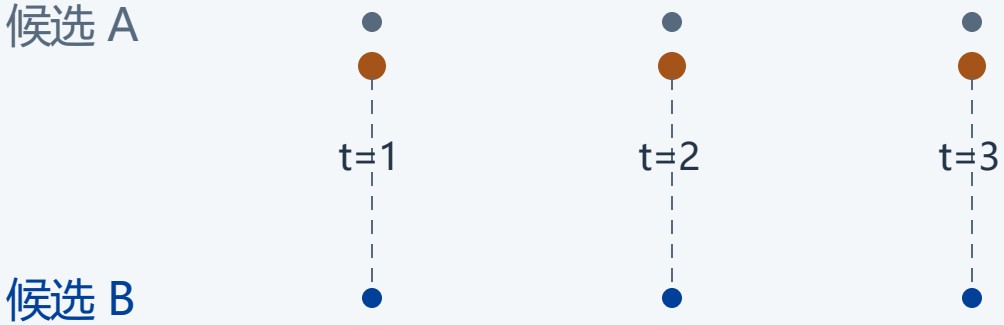


12条原始记录 → 12条有序记录 → 11条唯一观测 → 10个点 → 2段

独立例子 A | GPS偏离道路时，怎么匹配?

切换到一个独立的三时刻例子。每个观测点都有两个候选道路位置。

示意：按观测次序查看候选位置



橙点为GPS观测，灰点和蓝点为候选道路位置。

只选最近的道路?

A 离观测点较近。

还要检查连续选 A 时，路网中相邻候选位置是否容易到达。

下一页用代价描述这两项。

地图匹配的输出是一个推断的道路位置序列。

地图匹配①：候选道路与序列推断

定义与对象

对每个GPS观测生成候选道路位置，并结合观测误差和转移关系选择整个序列。

$$J(r)=\Sigma_t\ E_t(r_t)+\Sigma_{t=2}^{T}\ C_t(r_{t-1},r_t)$$

方法与符号

E为观测代价，C为转移代价；候选道路是隐状态，GPS是观测。假设转移仅依赖前一状态。

适用条件与边界

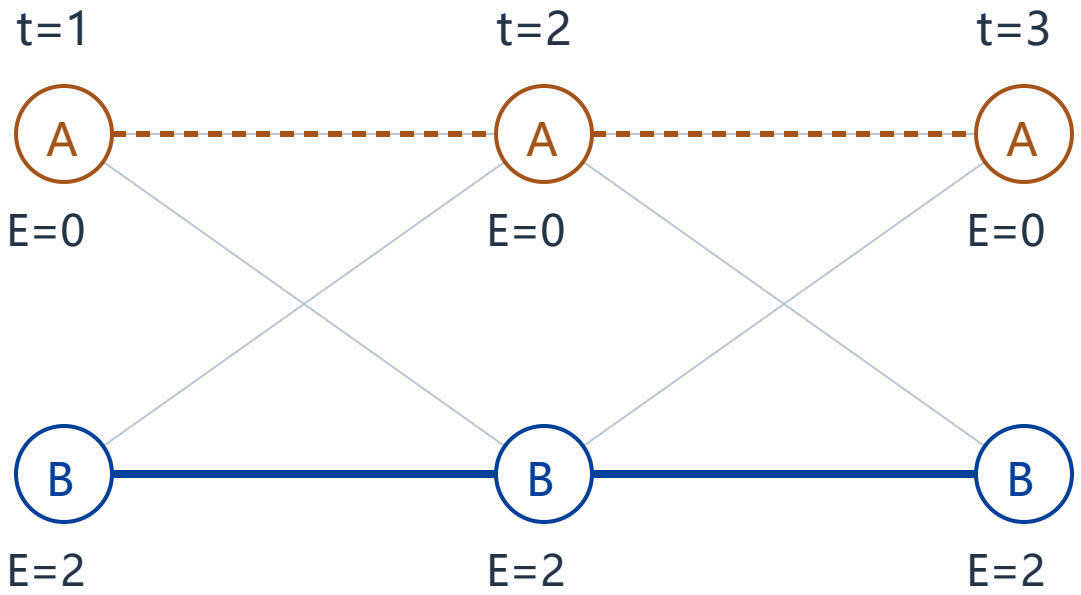
HMM概率可取负对数转为代价；本例使用构造代价表，不含完整路网检索和参数估计。

算例 / 解释

仅选最近道路，
可能得到需要异常绕行或不连贯的候选序列。

地图匹配②：局部最近与全序列最优

$E_t(A)=0, E_t(B)=2; C(B,B)=0$，其余$C=8$



蓝线：BBB；橙线：逐点最近AAA

本例代价为教学构造，未归一化为HMM概率；候选状态格不是实际道路地图。

计算步骤与结果

三个时刻都有候选A、B。

逐点最小：AAA
观测0 + 转移16 = 16。

连续B：BBB
观测6 + 转移0 = 6。

地图匹配｜为什么连续选 B 更合理?

沿用三时刻、两个候选的构造代价。比较单点距离与整段路径的解释。

逐点最近 → A → A → A

观测代价合计 0，转移代价合计 16。

每个位置都离观测点近，但这组位置之间的转移代价较高。

序列最优 → B → B → B

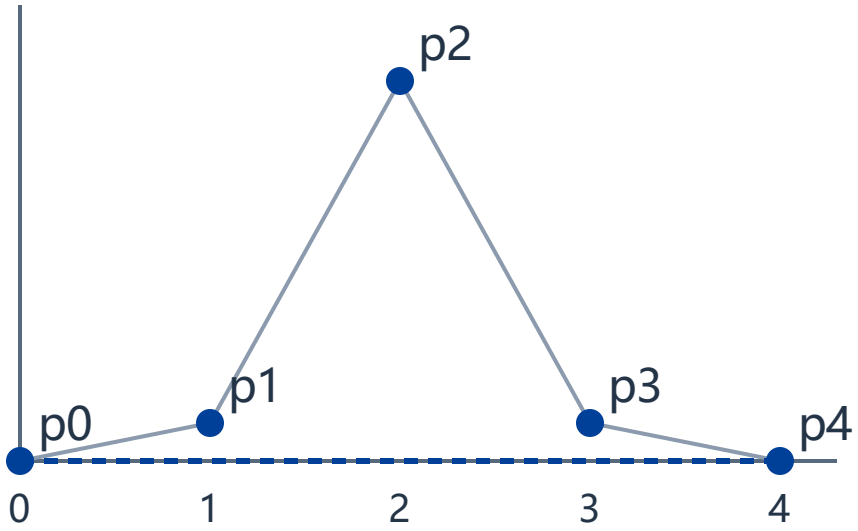
观测代价合计 6，转移代价合计 0。

这条候选序列的总价最低。动态规划递推与回溯见备用页。

地图匹配同时使用观测和道路间的转移信息，结果应标为推断。

独立例子 B | Douglas–Peucker 轨迹简化

$$d_{max}=\max_i d(p_i,[p_a,p_b])$$



坐标单位：m

$p_1=(1,0.2)$

$p_2=(2,2)$

$p_3=(3,0.2)$

计算步骤与结果

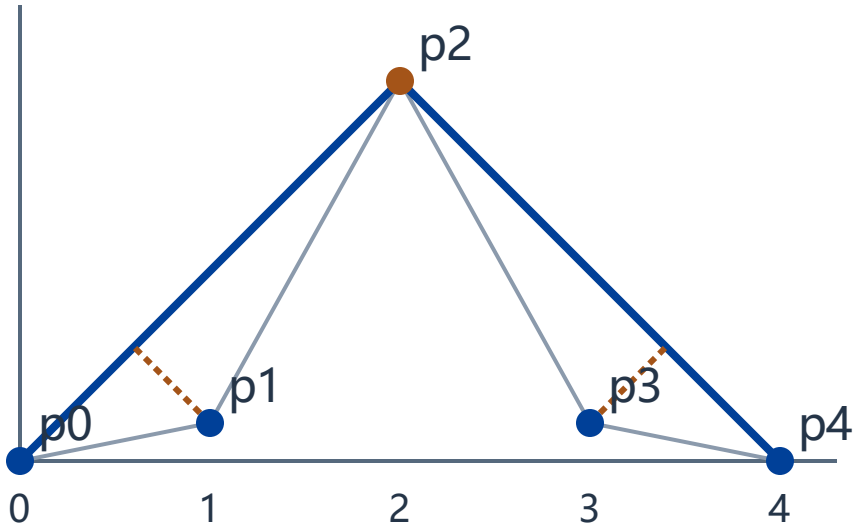
用首尾点连线近似整段。
若d_max≤ε，删中间点；
否则保留最远点并分裂。

本例ε=0.6 m。
请找出第一轮最远点。

使用局部平面坐标（米）和点到线段距离；简化几何位置不等于保留速度、停留或时间语义。

Douglas–Peucker②：保留最远点，再递归

$d(p_2,[p_0,p_4])=2>0.6$



坐标单位：m

$p_1=(1,0.2)$

$p_2=(2,2)$

$p_3=(3,0.2)$

计算步骤与结果

第一轮保留峰值p_2。

递归处理两侧：

$d(p_1,[p_0,p_2])\approx0.566$

$d(p_3,[p_2,p_4])\approx0.566$

均≤0.6，删除p_1、p_3。

每个子段重新计算距离，不是按第一次距离给所有点一次性排序。相邻端点构成的子段直接结束。

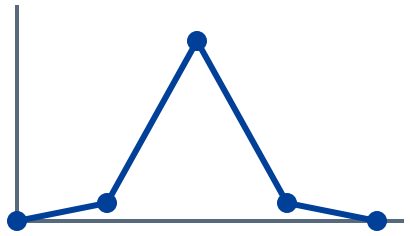
Douglas–Peucker③：结果与容差敏感性

$\varepsilon=0.5 \rightarrow 5$点;

$\varepsilon=0.6 \rightarrow 3$点; $\varepsilon=2.1 \rightarrow 2$点

ε=0.5

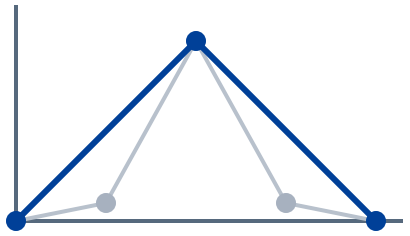
保留5点



相同坐标比例

ε=0.6

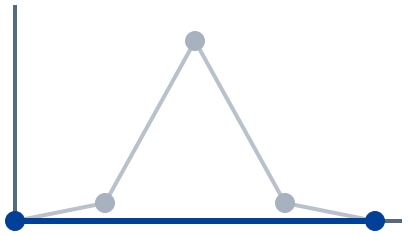
保留3点



相同坐标比例

ε=2.1

保留2点



相同坐标比例

计算步骤与结果

ε=0.6时输出：

$p_0 \rightarrow p_2 \rightarrow p_4$。

容差越大可保留更少点。
但峰值与转折也可能丢失。

原始观测应另外保存。

容差 ε 控制几何近似。若后续要分析速度或停留，请保留原始观测及时间戳。

清洗后的GPS记录可以怎样表示?

回到主案例。按分析问题确定样本单位，然后再构造输入。

按事件表示

样本是一次定义明确的事件。

例如，用停留规则提取停留点，并记录开始时刻和持续时间。

按网格表示

样本是一个网格与时间窗的组合。

例如，统计每格每5分钟的观测点数。

按 OD 网络表示

样本是区域间的一条有向边。

先识别行程起终点，再汇总起区到终区的行程数。

同一批观测能生成多种表示。先说清楚每个样本代表什么。

课堂演示｜用 Python 复核前三步

练习包02中执行 python run.py。输入是这12条模拟 GPS 记录。

核对输出文件

metrics.json：raw = 12，unique = 11，clean = 10，rejected = 1。

clean.csv：保留的10条观测。

rejected.csv：速度超限的 #8。

回到课堂规则

去重去掉 #4，速度过滤拒绝 #8。两个动作分别计数。

分段请按第46页手算：最后的180 s空档超过 120 s，得到两段。

脚本输出可复核排序、去重与跳点检查。分段结果在第48页。

回顾｜每一步改变了什么?

步骤	条数	变化
排序	12 → 12	把 #6 放回 #5 前，恢复观测先后。
去重	12 → 11	移除与 #3 完全相同的 #4。
跳点检查	11 → 10	根据速度剔除 #8，保留 #9。
分段	10 → 10	断开 #10 到 #11 的连线，得到2段。

课堂检查：采样空档的分段阈值改为 200 s，这10个点会分成几段?