《时空数据分析与挖掘》 · 第03讲

时空关联规则挖掘

从规则定义和算法推演到三篇研究案例

时间关联 / 空间共位 / 时空序列

一张小票就是一条事务

小票 W01

牛奶、面包、鸡蛋

一张小票是一条事务。T_1 表示第 1 张小票里的商品。

把商品写成集合

$$T_1 = \{A, B, C\}$$

A 代表牛奶，B 代表面包，C 代表鸡蛋。

商店里的全部可选商品

$$I = \{A, B, C, D\}$$

I 是项全集。D 代表苹果，这张小票买的是 I 中的三种商品。

十张小票组成事务库

小票	买了什么	事务	小票	买了什么	事务
W01	牛奶、面包、鸡蛋	{A, B, C}	W06	牛奶、面包	{A, B}
W02	牛奶、面包	{A, B}	W07	面包、鸡蛋	{B, C}
W03	牛奶、面包、鸡蛋	{A, B, C}	W08	面包	{B}
W04	牛奶、面包	{A, B}	W09	鸡蛋	{C}
W05	牛奶、鸡蛋	{A, C}	W10	苹果	{D}

$$\mathcal{D} = [T_1, T_2, \ldots, T_{10}],\ N = 10$$

W01 是编号，对应 T_1。花体 $\mathcal{D}$ 表示整库，N 表示事务总数。

一条规则怎么读

选择前件 X 和后件 Y

X = {A}，Y = {B}。规则为 {A} ⇒ {B}

X 和 Y 是从 I 选出的非空且互不重叠的商品集合。

先按 X 筛选，再检查 Y

买牛奶的小票里，有多少也买了面包?

前件 X 是筛选条件。后件 Y 是接下来检查的商品。

用 W05 走一遍

W05 = {A, C}

W05 有牛奶，所以进入筛选结果。它没有面包，因此后件未命中。

支持度的分母是全部小票

在全部十张小票中，牛奶和面包一起出现了几次?

W01	W02	W03	W04	W05	W06	W07	W08	W09	W10
同时有	同时有	同时有	同时有	—	同时有	—	—	—	—

支持度 = 共同出现的笔数 ÷ 事务总数

$$\sup(A \Rightarrow B) = n(\{A, B\}) / N = 5 / 10 = 50\%$$

$n(\{A, B\})$ 是同时含有 A 和 B 的小票数。

置信度的分母是满足前件的小票

先用箭头左边的条件筛小票，再数箭头右边的命中。

规则方向	先筛出哪些小票	两样都买	置信度
牛奶 ⇒ 面包	6 张买牛奶的小票	5 张	**5/6 ≈ 83.3%**
面包 ⇒ 牛奶	7 张买面包的小票	5 张	**5/7 ≈ 71.4%**

$$\text{conf}(X \Rightarrow Y) = n(X \cup Y) / n(X)$$

$n(X \cup Y)$ 数同时包含两边商品的小票，$n(X)$ 只数含前件的小票。

提升度把置信度放回总体基准比较

有前件时

买牛奶的小票中，5/6 ≈ 83.3% 也买了面包

这就是牛奶 ⇒ 面包的置信度。

看总体基准

全部小票中，7/10 = 70% 买了面包

基准率是后件 B 在全部小票中的出现比例。

把两个比例相除

lift(A ⇒ B) = (5/6) ÷ (7/10) = 25/21 ≈ 1.19

买牛奶时，面包的出现率约为总体基准的 1.19 倍。

用降雨和拥堵检验三个指标

每条事务是一条道路的一天早高峰记录。

100 天里，25 天下雨，其中 20 天拥堵。

三个假设情形	总体拥堵率	雨天拥堵率	提升度	怎么读
甲	50%	80%	**1.60**	雨天拥堵比例更高
乙	80%	80%	**1.00**	雨天拥堵比例相同
丙	90%	80%	**0.89**	雨天拥堵比例更低

下雨 ⇒ 拥堵的支持度 = 20/100 = 20%，置信度 = 20/25 = 80%。

三种情形的共同命中数相同，提升度随总体拥堵率改变。

关联规则挖掘有什么用

应用	一条事务是什么	可能挖到的规则	发现后怎么用
交通预警	路段的一天早高峰	{下雨、附近有活动} ⇒ {拥堵}	筛选待验证的预警条件
设备运维	设备的一小时记录	{高温、强振动} ⇒ {报警}	检查常伴随报警的指标组合
软件分析	一次完整使用会话	{使用导入} ⇒ {使用导出}	根据功能共用调整入口

从多个条件中自动找出经常共同出现的组合，再结合任务检查结果。

从一条手算规则走向自动挖掘

把刚才的十张小票交给算法筛一遍。

最小支持度 40%，最小置信度 80%

候选规则	支持度	置信度	筛选结果
牛奶 ⇒ 面包	50%	83.3%	**保留**
面包 ⇒ 牛奶	50%	71.4%	低于置信度门槛

先按支持度找频繁组合，再拆出候选规则，按置信度筛选。

早高峰联合排查从哪里入手

全市筛查

20 条「片区 × 日期」记录。找哪些交通条件组合常伴随公交晚点。

片区核查

六个测点的四天车流原表。逐步检查曲线、事件顺序、位置和时延。

核查结果

列出值得核查的条件和片区，并说明每种结果来自哪一层数据。

一条早高峰记录怎么写成事务

A 主干道高流量　**B 匝道高流量**　**C 支路高流量**　**D 公交晚点**

E 降雨　F 施工　G 临时管制　H 活动散场

记录标签	条数	记录标签	条数
ABCD	5	ACF	1
ABE	4	BF	2
ACE	1	CF	1
BCE	1	DF	1
ADE	1	AG	1
AB	1	H	1

例如 ABCD 表示该片区当天三类道路均有高流量，且公交晚点。

为什么先数单项，再数两项

设置门槛

最小支持度 25%，即 20 条中至少出现 5 条

先数每种标签的出现次数。

先筛单项

G = 1，H = 1，留下 A、B、C、D、E、F

含 G 或 H 的任何组合，至多出现 1 次。

手算两项

n(AB) = 5 + 4 + 1 = 10

原表中只有 ABCD、ABE、AB 三行同时包含 A 和 B。

三项候选先查两项子集

拼出候选	先检查两项子集	接下来怎么做
AC + AE → ACE	AC、AE 达标，CE 只有 2 条	**跳过计数**
AB + AE → ABE	AB、AE、BE 都达标	**回表数到 4 条，未达标**
AB + AC → ABC	AB、AC、BC 都达标	**回表数到 5 条，保留**

每条包含 ACE 的记录都含 CE。CE 只有 2 条，ACE 最多也只有 2 条。

三项达标以后，怎样查四项

先连接

ABC + ABD → ABCD

三项组合的前两个字母相同，可以连接成一个四项候选。

再查子集

ABC、ABD、ACD、BCD 都达到 5 条

ABCD 的四个三项子集都达标，才进入原表计数。

最后计数

n(ABCD) = 5，支持度 = 5/20 = 25%

各轮实际计数 8 + 15 + 5 + 1 = 29 个候选。

从频繁组合读出待复核的规则

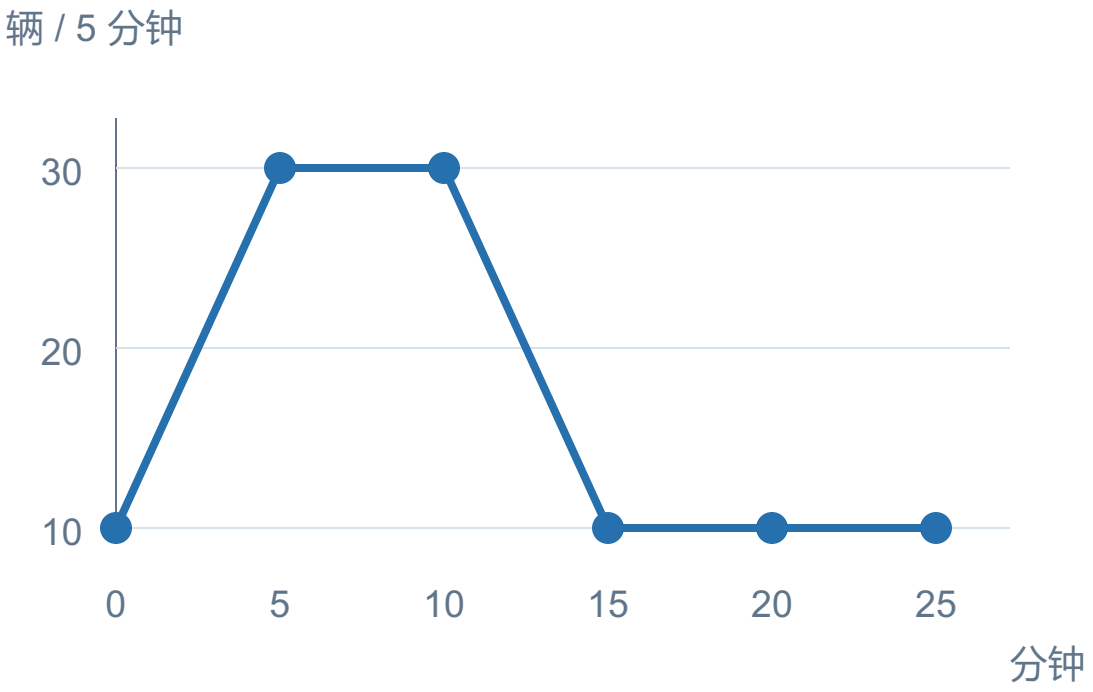
规则	共同命中	前件覆盖	置信度
ABC ⇒ D	5 条	5 条	**5/5 = 100%**
AB ⇒ CD	5 条	10 条	5/10 = 50%

三类道路都出现高流量的 5 条记录中，5 条都出现公交晚点。

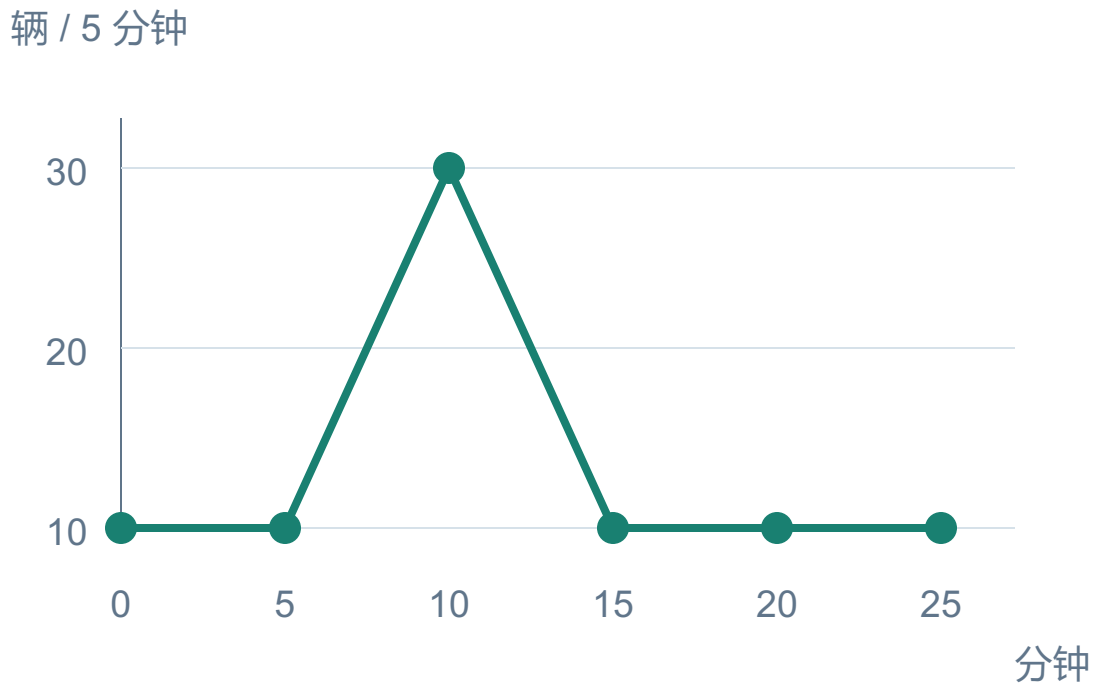
把这个条件组合作为候选，拿其他日期的片区记录复核。

DTW 比较错开时刻的高峰形状

D1 · A1

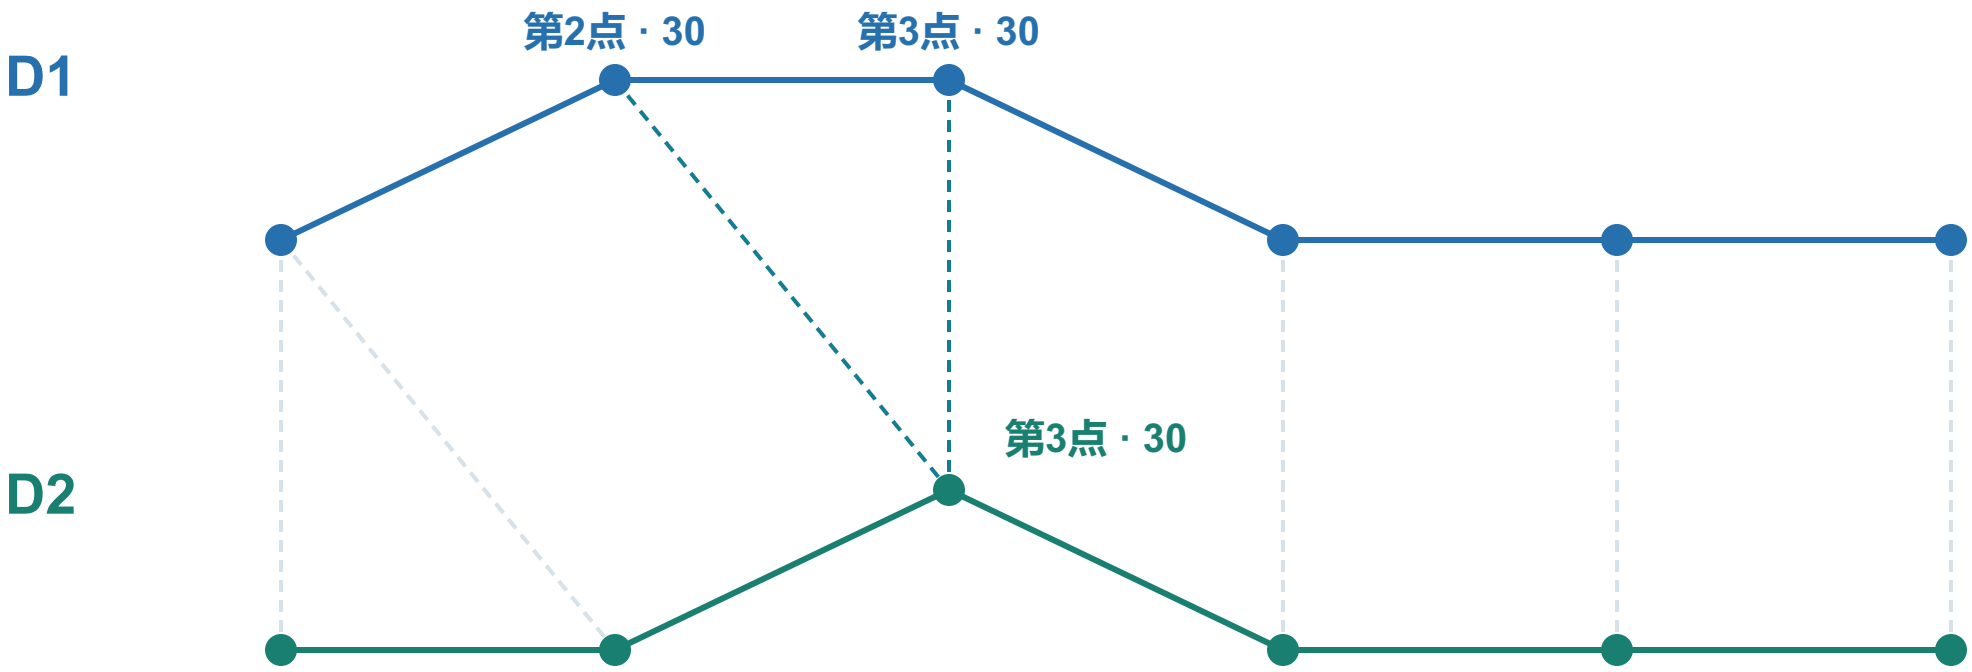


D2 · A1



D1 第 2 点是 30。配 D2 第 2 点的代价为 20，配第 3 点的代价为 0。

同刻逐点差 20，换一种配法差 0



D1 第 2、3 点都配给 D2 第 3 点。局部拉伸仍保持先后顺序。

填一格只算本格差和最小来路

累计代价	D2 第 1 点 10	D2 第 2 点 10	D2 第 3 点 30
D1 第 1 点 10	0	**0**	20
D1 第 2 点 30	20	20	**本格**

D(2,3) = |30 − 30| + min(上 20，左 20，左上 0) = 0

记下左上这条来路。横走或竖走时，只有其中一天换到下一点。

格子记的是从开头到这里的最小累计差。

回溯路线上的每一格就是一对点

从右下角沿来路倒走

(6,6) → (5,5) → (4,4) → (3,3) → (2,3) → (1,2) → (1,1)

把经过的格子倒过来读，得到按时间排列的配对。

看重复的行号和列号

(1,1)、(1,2)；(2,3)、(3,3)

D1 第 1 点配 D2 的第 1、2 点。D1 的第 2、3 点都配 D2 第 3 点。

读结果

两天的低位、高位和回落可以零差值对齐

两天实际高峰的开始时刻与持续时间仍可分别记录。

把连续的高流量记成一次事件

D1 · A1	0 分钟	5 分钟	10 分钟	15 分钟
车辆数	10	30	30	10
事件记录	低位	**首次跨到高位**	持续高位	回落

高流量阈值为每 5 分钟 25 辆。只有从低位跨到高位才记事件。

这一天 A1 只记 A1(5 分) 一次。保留测点、类别、日期和时刻。

PrefixSpan 在 A 后面的日志找下一项

日期	原日志	匹配 A 后还能看什么	能否接 B
D1	A → B → C	B → C	**可以**
D2	A → B → C	B → C	**可以**
D3	B → A	空	无后续事件
D4	C	无 A，移出该分支	无匹配前缀

A 后面的剩余片段组成投影库。B 在 2 天的剩余片段里出现，达到 2 天门槛。

从 AB 继续扩展，找跨天重复的顺序

匹配了 AB 再往后看

D1 还剩 C，D2 也还剩 C

两天都能把 A 后接 B 的前缀延长为 A → B → C。

按日计支持度

support(A → B → C) = 2/4 = 50%

分母用原库的四天，当前例子至少两天达标。

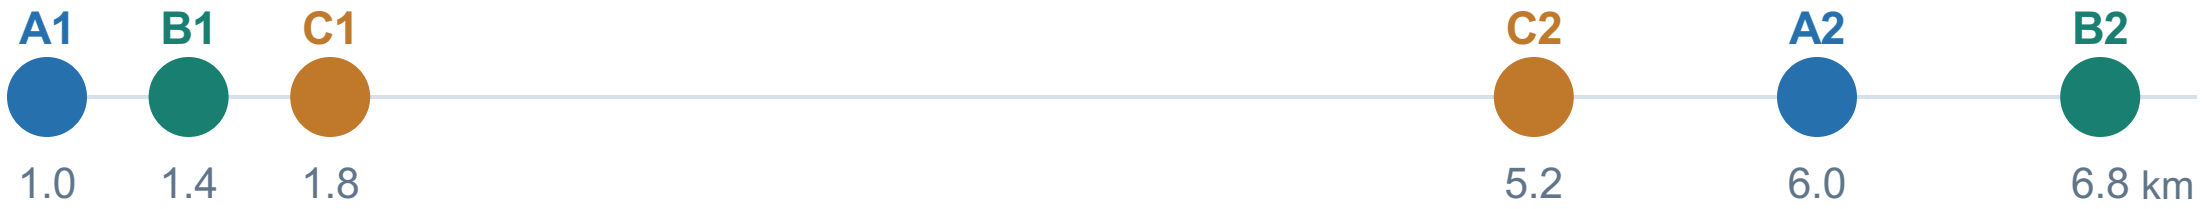
把结果用起来

把 A → B → C 列为待核查的顺序

接下来要查这几个事件在地图上是否靠得够近。

Joinless 找三类测点集中的片区

观测期内曾出现高流量的六个测点



A_1、A_2 主干道　　B_1、B_2 匝道　　C_1、C_2 支路

筛选条件是三类各找一个测点，三对距离都不超过 1 km。

这里比较测点位置。日期用来划定观测期。

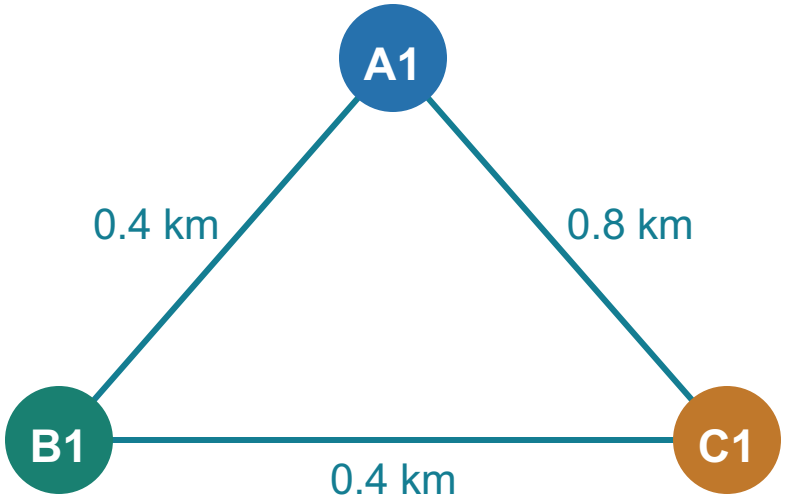
以 A 为中心，把 8 组缩到 2 个星型

中心 A	1 km 内的 B	1 km 内的 C	星型候选
A1	B1，0.4 km	C1，0.8 km	**(A1, B1, C1)**
A2	B2，0.8 km	C2，0.8 km	**(A2, B2, C2)**

三类各 2 个点，直接拼有 8 组。查中心的邻居后，只有这 2 组需要补验外围。

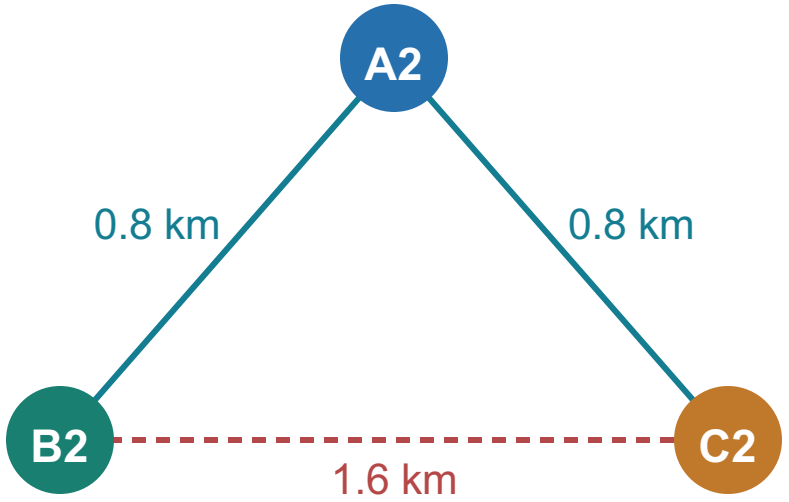
补查 B–C，两个星型只留一组

组合 1



完整共位，保留

组合 2



B2 与 C2 太远，剔除

以 A 为中心找 B 和 C。中心两条边通过之后，还要检查 B—C。邻接阈值 1 km。

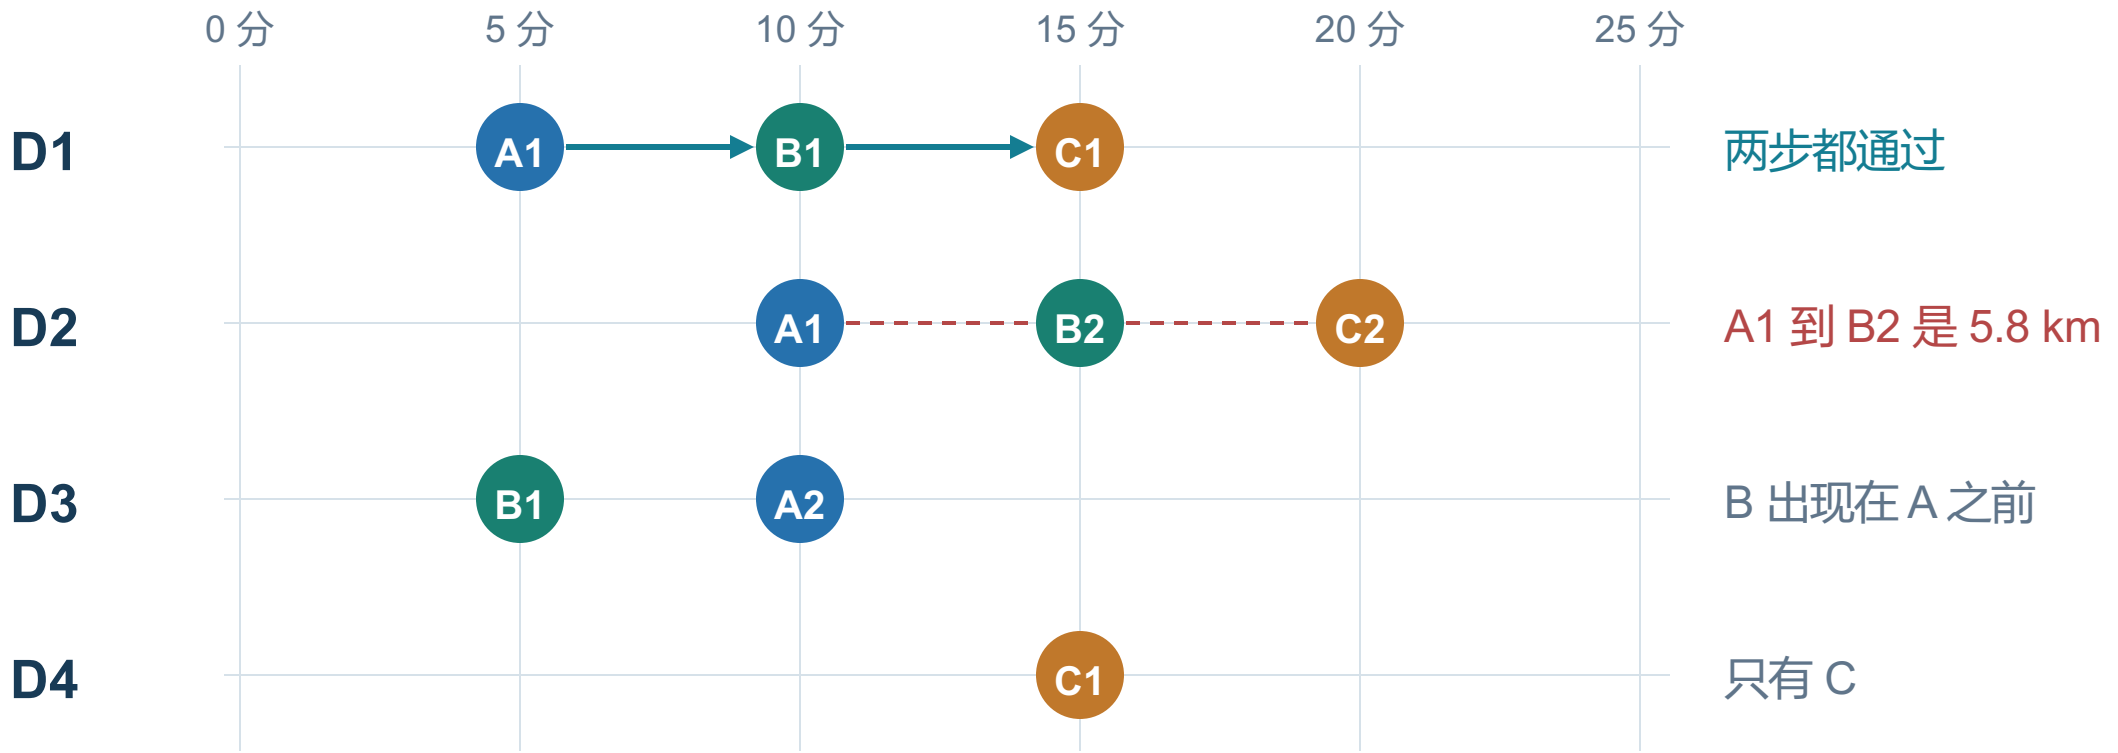
PI 取覆盖最少的一类

类别	完整共位中出现的测点	该类总数	参与率
A 主干道	A1	2	1/2
B 匝道	B1	2	1/2
C 支路	C1	2	1/2

PI = min(1/2, 1/2, 1/2) = 0.50

A1、B1、C1 所在片区进入联合排查清单。

STS-Miner 检查 ABC 能否在附近接成链



检查同一天、横纵各差 ≤ 1 km、0 < 时差 ≤ 5 分钟。只有 D1 接通。

从 A 接上 B，再从尾事件找 C

起点 A	当天的 B	结果
D1 · A1 (5 分)	B1 (10 分)	**相差 0.4 km、5 分，通过**
D2 · A1 (10 分)	B2 (15 分)	相差 5.8 km，空间超限
D3 · A2 (10 分)	B1 (5 分)	B 发生在 A 之前，时序超限

AB 的尾事件只有 D1 · B1 (10 分)。

从它找 C，接到 D1 · C1 (15 分)，间隔 5 分钟、距离 0.4 km。

为什么接得上还要和背景比

先找到具体链

D1 接成一条 A1 → B1 → C1。接下来想知道这种接法是否值得继续查。

比较背景频率

如果 B 在全域本来就密，A 附近遇见 B 也更常见。

DR 看一步有多密

把起点邻域里的后件密度，除以全观测范围内的同类后件密度。

两步 DR 用了不同的起点窗

单窗 2 km × 2 km × 5 分钟 = 20 km²·min

全域 18 km² × 30 分钟 × 4 天 = 2160 km²·min

步骤	起点窗数	局部密度	背景密度	DR
A → B	3 个 A 窗	1 / (3 × 20)	3 / 2160	**12**
AB → C	1 个尾事件窗	1 / 20	3 / 2160	**36**

局部密度计合格连接，背景密度计四天内的全部同类后件。

SI 看最弱一步，低分前缀停止扩展

两步接得上

SI(A → B → C) = min(12, 36) = 12

若 SI 门槛为 10，保留这个类型模式。

试一条接不上的分支

A → C 的合格连接为 0，SI = 0

D1 的 C 比 A 晚 10 分钟，已经超过单步的 5 分钟。

按前缀剪枝

停止扩展 A → C → …

A → B → C 的前缀是 A → B，可以先经 B 再接 C。

同一条时空链也可以按日计数

提问	计数口径	这四天的答案
这条链覆盖几天	命中链的日期 ÷ 全部日期	**1/4，支持度**
有 A 的日子里几天接成链	命中链的日期 ÷ 出现 A 的日期	**1/3，置信度**
每一步相比背景有多密	沿前缀逐步算 DR，再取最小值	**12，SI**

按日计数时，每天有多条合格链也只计一次。D1 是唯一命中日。

五种算法各给排查带来什么

方法	这组数据的结果	拿结果做什么
Apriori	ABC ⇒ 公交晚点	在其他日期复核条件组合
DTW	两条流量曲线对齐代价 0	挑出形状相近的日子对照
PrefixSpan	ABC 顺序出现于 2/4 天	列出值得核查的事件顺序
Joinless	1 组完整共位，PI = 0.50	圈定三类测点集中的片区
STS-Miner	D1 接通，SI = 12	回看接通的时刻、位置和背景

同样写成 ABC，D2 为什么被排除

PrefixSpan 的判断

D2 的 A、B、C 按顺序发生，所以贡献 1 天支持。

STS-Miner 的判断

D2 的 A1 与 B2 相差 5.8 km，第一步就接不上。

实际排查怎么做

保留 D1 的具体时刻和测点，核对路网连接与其他日期的重复情况。

第二节 发现关系以后，怎样把它用起来?

01

相似模式

道路之间的时空模式
组织分组预测

02

多源关系

事件、气象与心理表征
选择和融合信息

03

有向时序依赖

黑盒系统的监控指标
联合预测与资源决策

沿着场景、观察、关系、利用和证据读三篇论文。

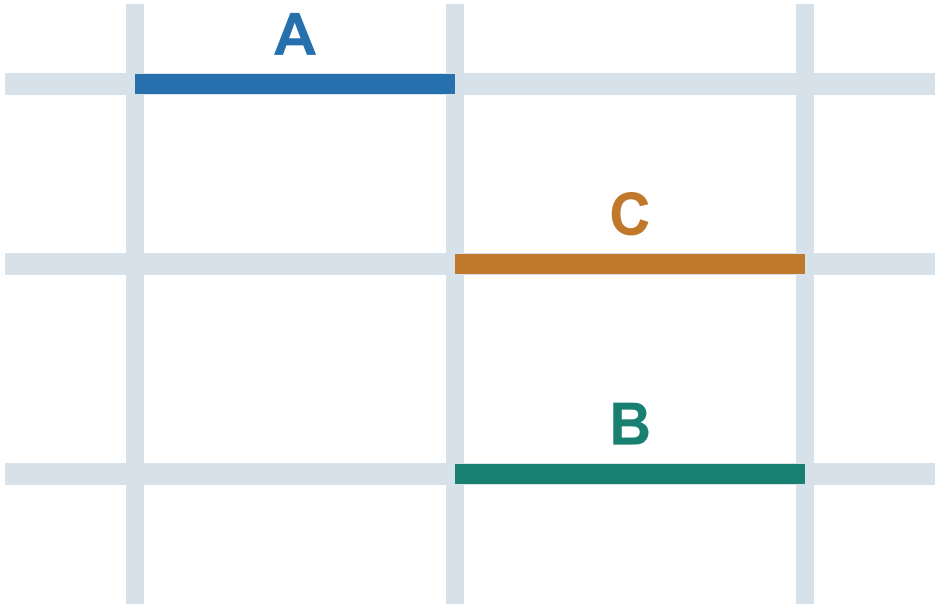
MetaSTC 要解决什么？ 预测整张路网的车速

把问题拆开	以早上 08:00 为预测时刻
场景	交通管理者想提前知道哪些路段可能变慢。
手头有什么	每条路最近一小时的车速，共 12 个点。还有道路等级、车道数等属性。
要交什么	给每条路预测未来半小时的车速，每 5 分钟一个值，共 6 个。
难在哪里	路网很大。不同路段高峰来得早晚不一，一套参数难以兼顾。

读下一页时，先找不同道路的速度曲线在哪里出现分岔。

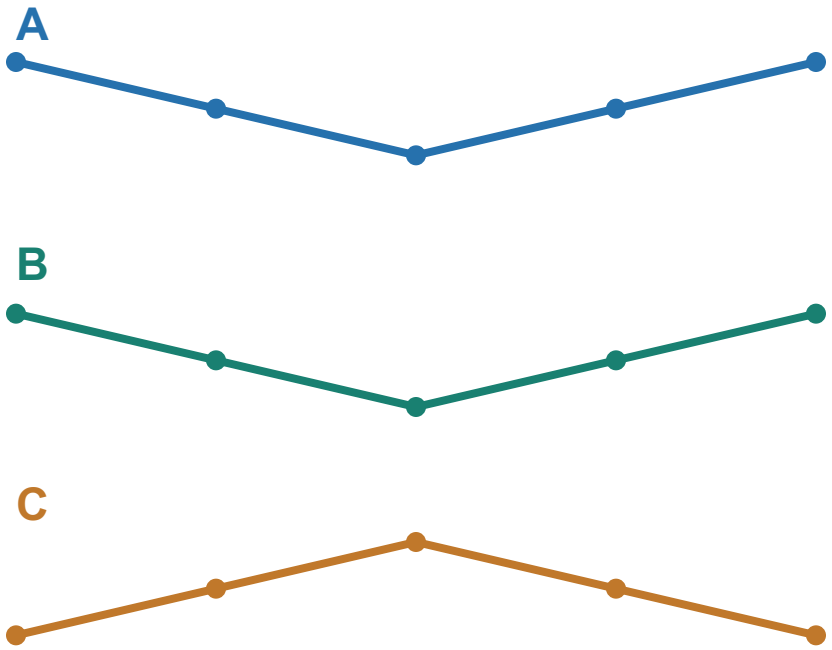
场景 地图上的每条道路都有自己的时间曲线

道路位置



简化路网 · 构造位置

各道路的历史车速

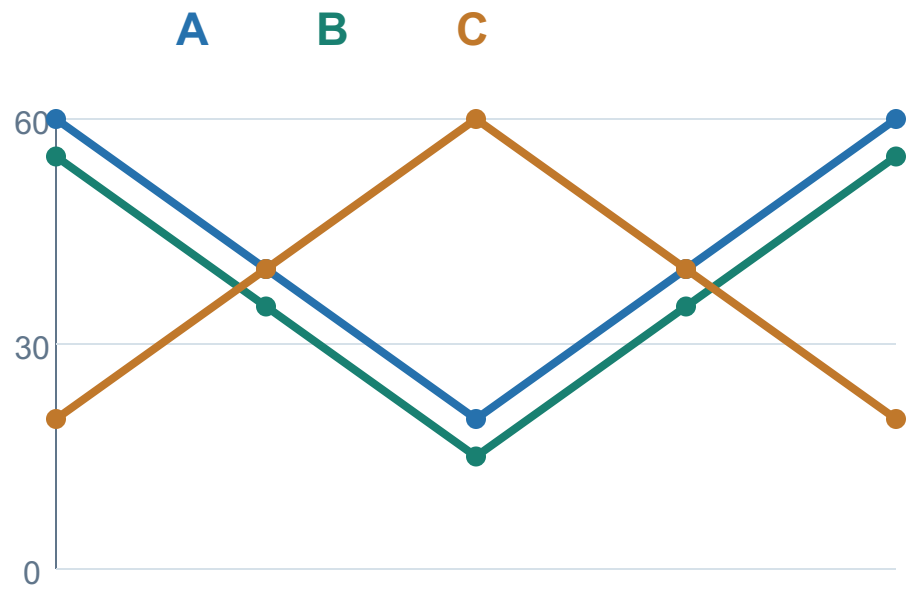


时间向右 →

先确定每条曲线属于哪条路，再判断哪些道路的变化模式相似。

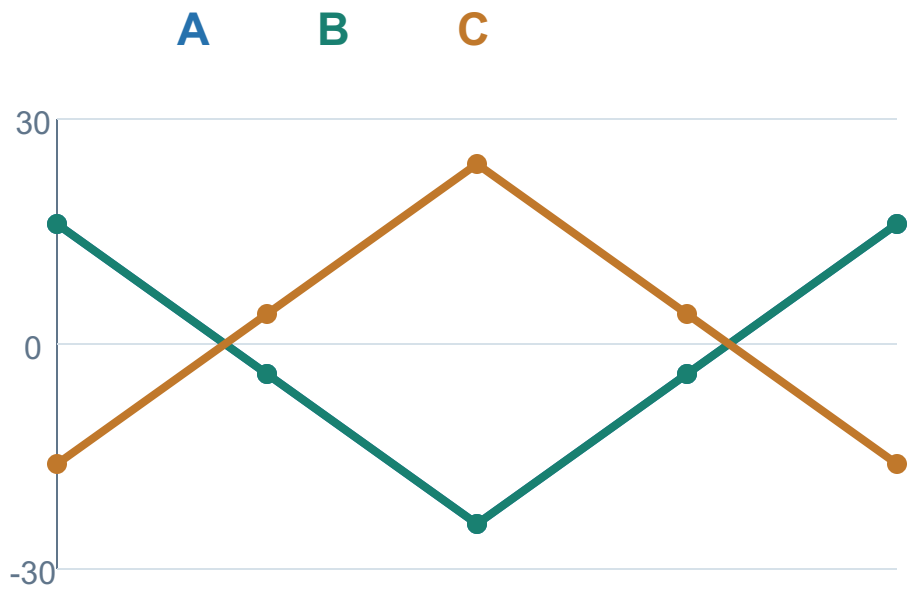
观察教学曲线 平均速度与形状相似是两件事

原始车速（教学值）



均值 A=44，B=39，C=36

各自减去均值以后



A、B 完全重合，C 的变化方向相反

形状相似帮助寻找共享模式。论文在学习到的时空表示上聚类。

道路表示结合静态属性与日周周期

空间表示

h_s = Embedding(道路属性)

论文特征包含道路等级、车道数、位置等

时间表示

h_t = Dense(历史速度, Traffic2Vec)

Traffic2Vec 含线性项、日周期项、周周期项

门控后聚类

$h = [G_s \odot h_s \,\|\, G_t \odot h_t]$

$\odot$ 为逐元素相乘，$\|$ 为拼接，h 进入 K-Means++

分组依据是一条路的时空特征

01

把道路写成数字

车道等静态属性
历史速度和日、周周期

02

门控调整信息比重

例：时间特征 5
门控为 0.2，保留 1

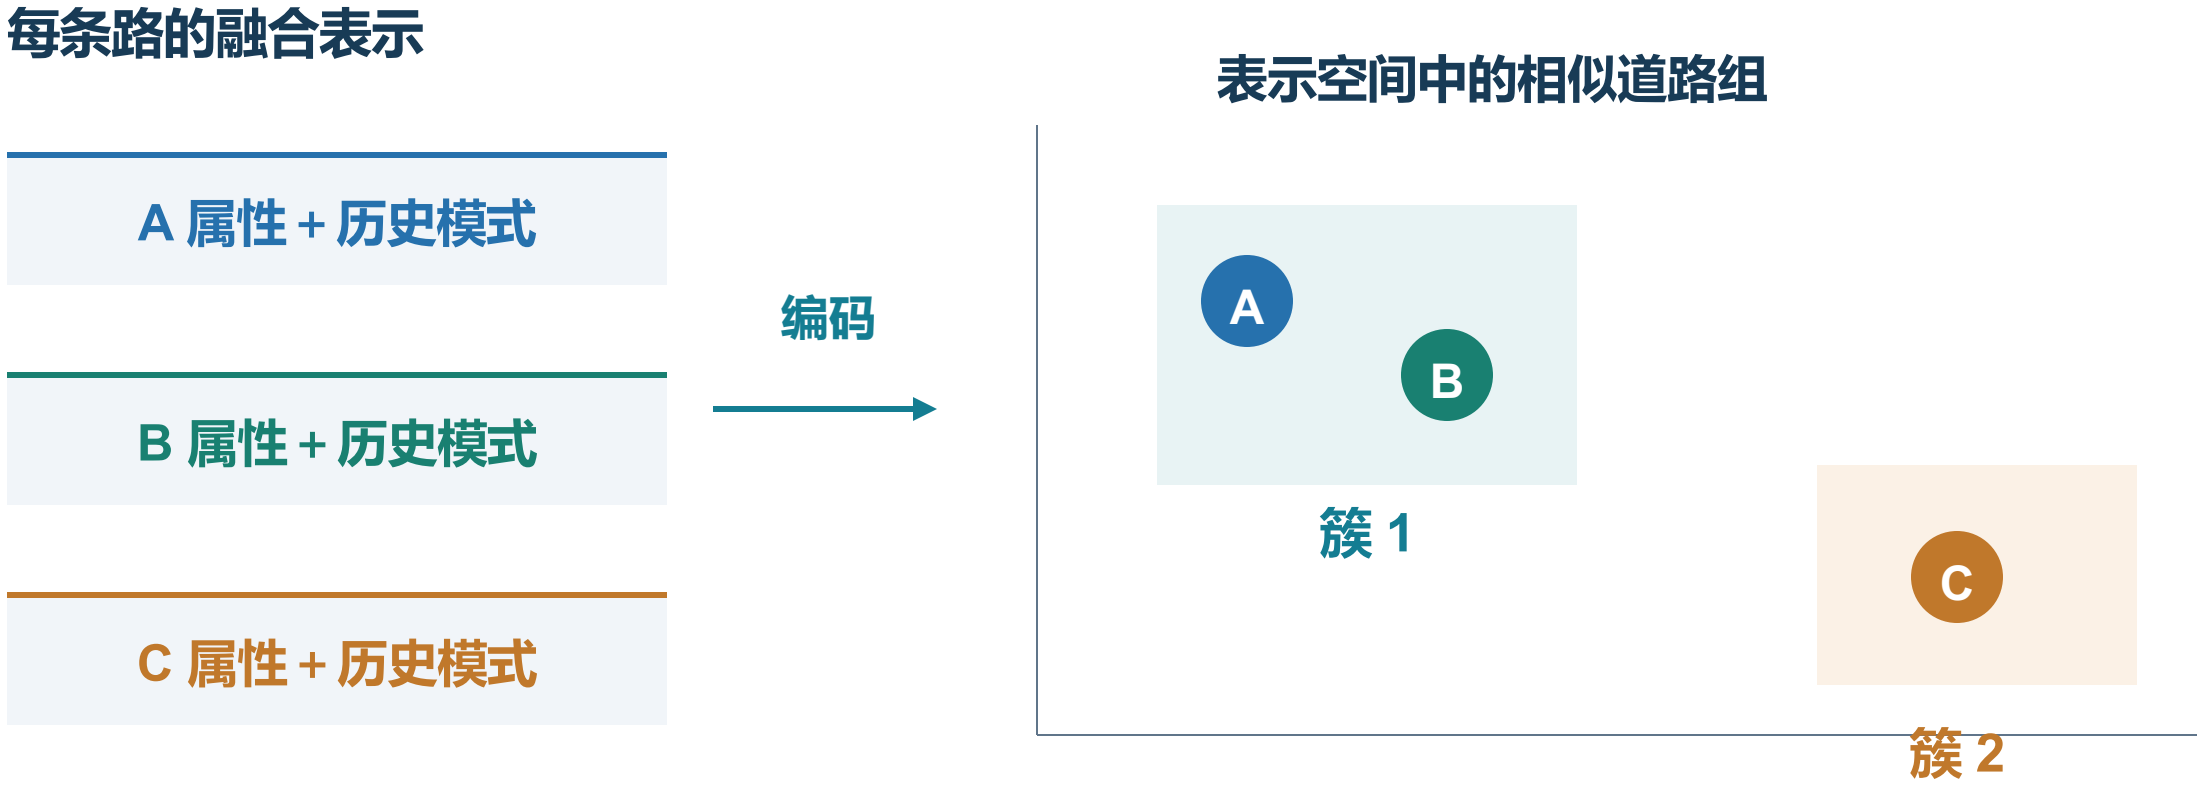
03

相似表示归同组

对融合后的向量
用 K-Means++ 分组

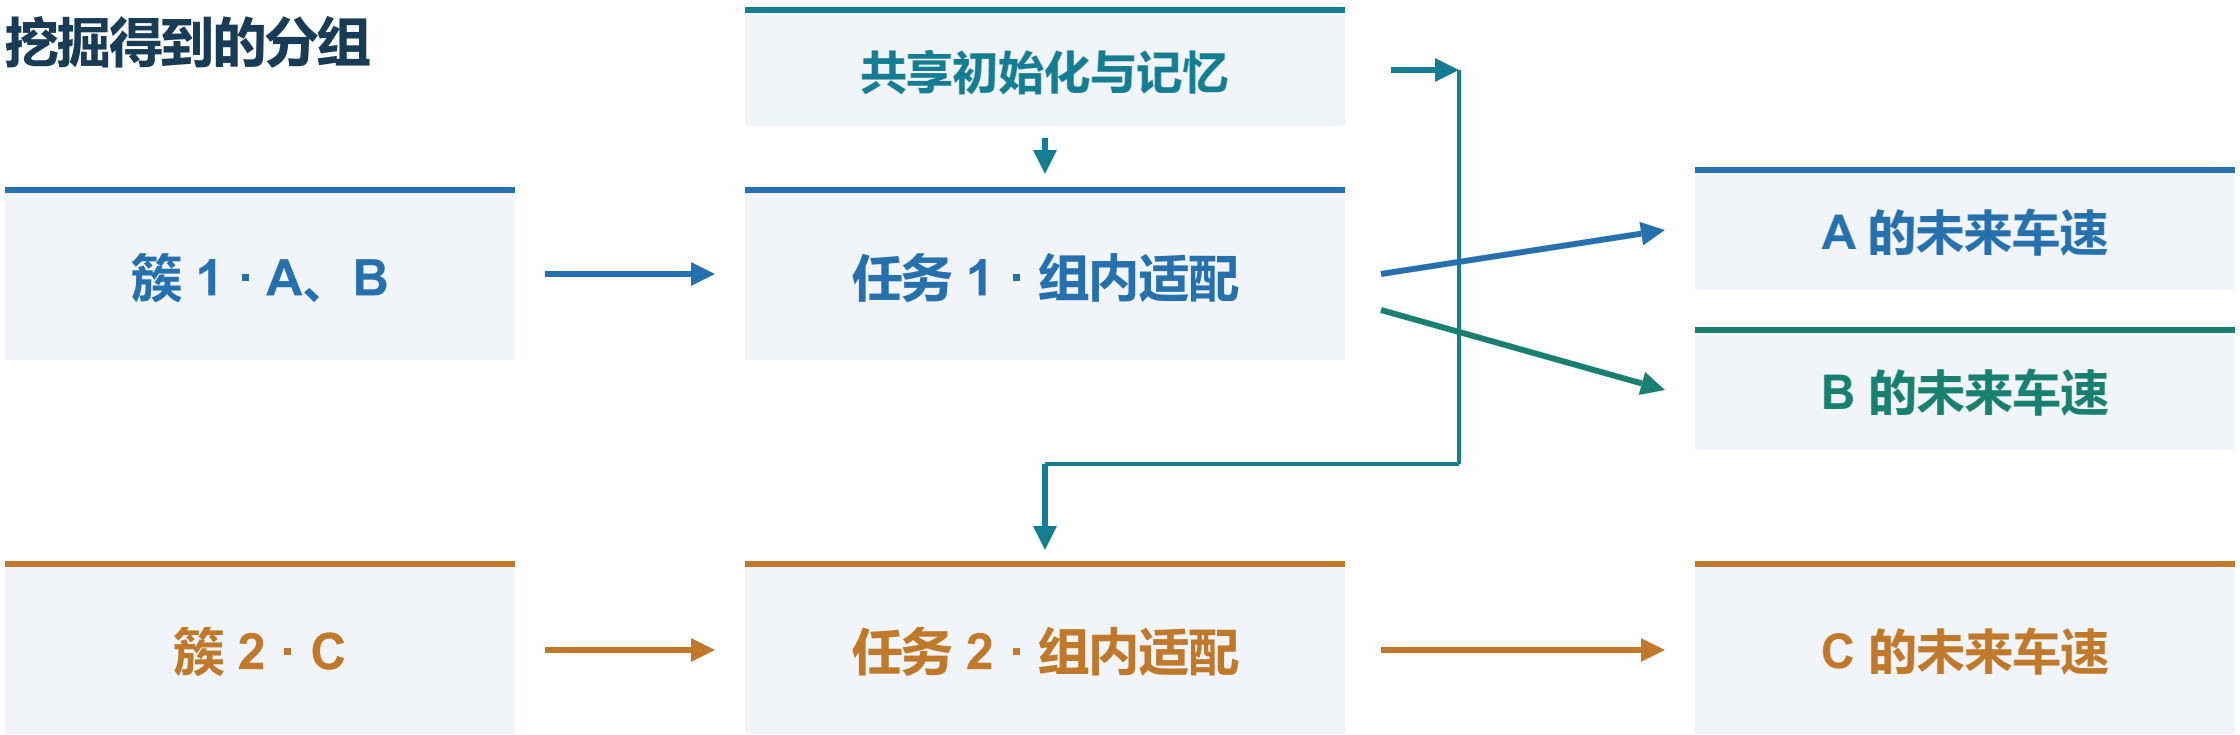
同一组道路共用组内预测任务，分组依据来自两类信息。

挖掘结果 相似时空表示形成道路簇



簇号将成为预测子任务的分组依据。图中两个簇用于教学。

怎样利用 相似模式决定谁一起学习、谁分别适配



聚类组织谁一起学习，适配处理组间差异，最终逐条道路输出预测。

元学习用支持集适配，用查询集改初始化

01

初始化

共享参数
簇相关初始化

02

组内更新

支持集计算梯度
得到本组参数

03

外层更新

查询集评估本组
更新全局参数

查询集衡量适配后的泛化。最终测试数据另行保留。

元学习手算 两个组从同一初值往不同方向调

组	共同初值	在支持集测得的梯度	本组更新后的参数
甲	1.0	+2	$1.0 - 0.1 \times 2 = 0.8$
乙	1.0	−1	$1.0 - 0.1 \times (-1) = 1.1$

下一步在查询集看 0.8 和 1.1 各自是否好用，再反馈到共享初始化。

在同一数据上比较接入框架前后的 MAE

北京，历史 12 步	原骨干 MAE ↓	接入 MetaSTC 后 ↓
LSTM	4.837	3.534
FiLM	3.391	3.367

接入前后的差值随骨干而变。组件贡献需要单独对照。

MetaSTC 回看 挖出的模式簇改变了预测任务

观察

不同道路存在重复、相近和不同的时间模式。

关系输出

在道路属性与时间表示上得到相似模式簇。

任务用途

簇组织预测子任务，组内共享，组间适配。

https://gaoyucen.github.io/spatiotemporal-data-course/

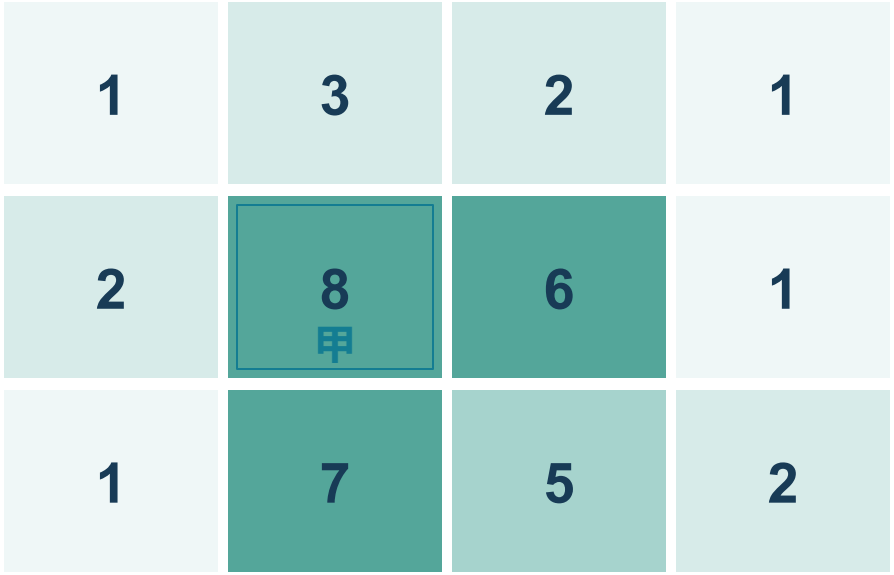
MAST 要解决什么？ 预测明天各区的事件数

把问题拆开	以上海奉贤区为例
场景	城市管理者想提前了解明天各片区会报告多少起涂鸦等事件。
手头有什么	每起事件的时间、位置和类别，以及对齐到各区的温度、降水、湿度。
要交什么	给每个网格、每种事件分别预测下一天的数量。
难在哪里	历史事件数相近的两个区，天气可能不同。只用事件历史会漏掉这项信息。

先看原论文里天气与事件如何一起变化，再看模型怎样使用天气。

场景 同一块区域同时记录事件与天气

区域网格 × 观测日期



格内数字为某类事件的当日记录数

区域甲 · 今天

事件 8 起

温度 28℃ · 降水 2 mm

湿度 75% · 历史逐日记录

预测甲区明天各类事件数

同一区域、同一时段对齐事件与气象。格数、数字均为课堂构造。

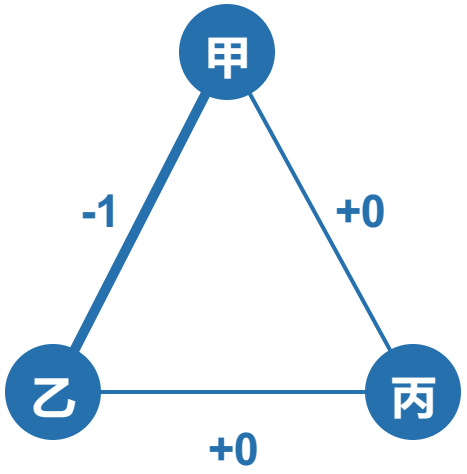
同一对区域，可以在不同的图里有不同关系

从哪种数据看	区域甲的三次记录	区域乙的三次记录	两区关系
温度（℃）	20、22、24	18、20、22	同涨，相关为 +1
某类事件数	2、4、6	6、4、2	反向，相关为 −1

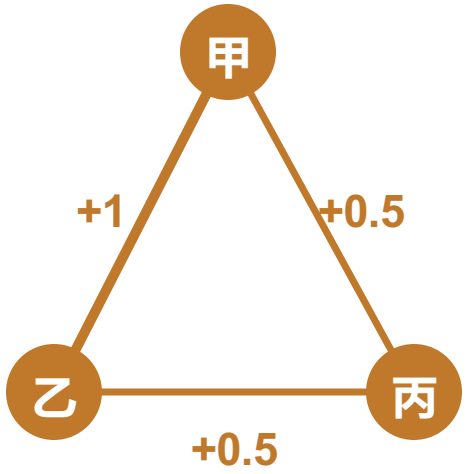
区域还是这两块，换一种数据，图上的边权就会变。

挖掘多源关系 同一批区域可以连接成四张图

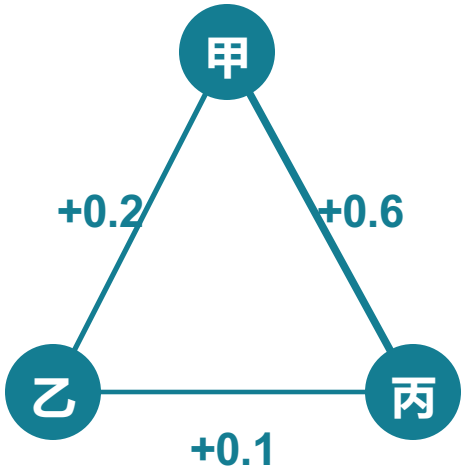
事件图



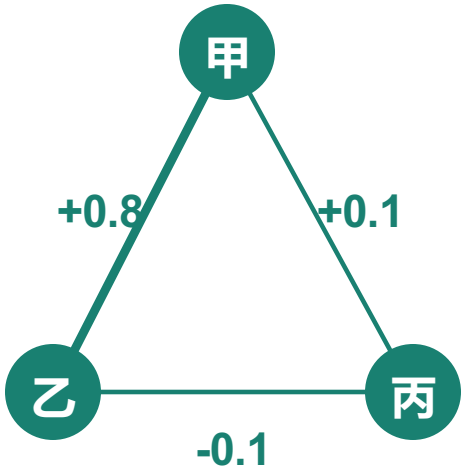
温度图



降水图



湿度图



节点相同，数据来源不同，区域间的边权随之改变。

构图用区域之间的 Pearson 相关。权重为教学示意。

怎样利用 关系矩阵决定区域向谁取信息



关系矩阵进入图卷积，改变目标区域从其他区域接收的信息。

心理因素 从机制假设走到可学习的区域表征

机制假设 · 原文依据相关研究提出

气象条件 ---------- 心理状态 ---------- 行为倾向

模型实现 · 从观测输入学习潜在表征

气象 + 事件嵌入 → MLP 编码心理因素 → 加到空间表征

可观测的气象与事件

模型学到的潜在特征

MLP 为多层感知机。心理因素表征通过事件预测任务学习和检验。

气象与事件共同构成心理因素表征

气象输入

$$M = [\text{温度} \,\|\, \text{降水} \,\|\, \text{湿度}]$$

气象投影后沿事件类型维复制，与事件表示对齐

学习表征

$$Psy = MLP([\text{对齐的气象投影} \,\|\, \text{事件投影}])$$

论文用两层全连接实现融合

并入主支路

$$H^K = H^R + Psy$$

将学习到的表征加到空间表示，再建模时间依赖

气象有两条用法 连接区域，也补充事件表征

01

区域之间

气象相似度写进图
决定区域如何交换信息

02

区域内部

气象和事件共同编码
得到心理因素表征

03

沿时间预测

加到空间特征上
再学习时间规律

这里的心理因素是模型学出的中间特征。论文用事件预测误差检验它。

时间建模需要看见周期与近期变化

周期依赖

用 FFT 找显著频率，按周期重排后用卷积提取周期模式。

近期动态

沿时间轴做卷积，再沿时间维汇聚，用于下一日预测。

对比学习把同一区域的两个视图拉近

配对	气象辅助分支	仅用事件的分支	训练目标
正样本	区域 A，事件 k	区域 A，事件 k	拉近
负样本	区域 A，事件 k	区域 B，事件 k	分开

两条分支共同提供训练信号，最后仍以未来事件数量评估预测。

按事件类型阅读 MAST 消融结果

模型（MAE ↓）	涂鸦	乱停车	损坏	盗窃
去心理因素模块	7.4100	4.2415	1.5854	2.4665
去对比学习	7.6884	4.3941	1.6833	2.4575
去气象变体	7.4037	4.2323	1.5556	2.4675
MAST	7.3774	4.2202	1.5803	2.4418

对照结果随事件类别变化。损坏类的最低 MAE 出现在去气象变体。

MAST 回看 多源关系参与传播、补充和筛选

观察

事件与气象共同变化，关联程度随事件和指标改变。

关系输出

四类区域关系与融合关系，以及潜在心理因素表征。

任务用途

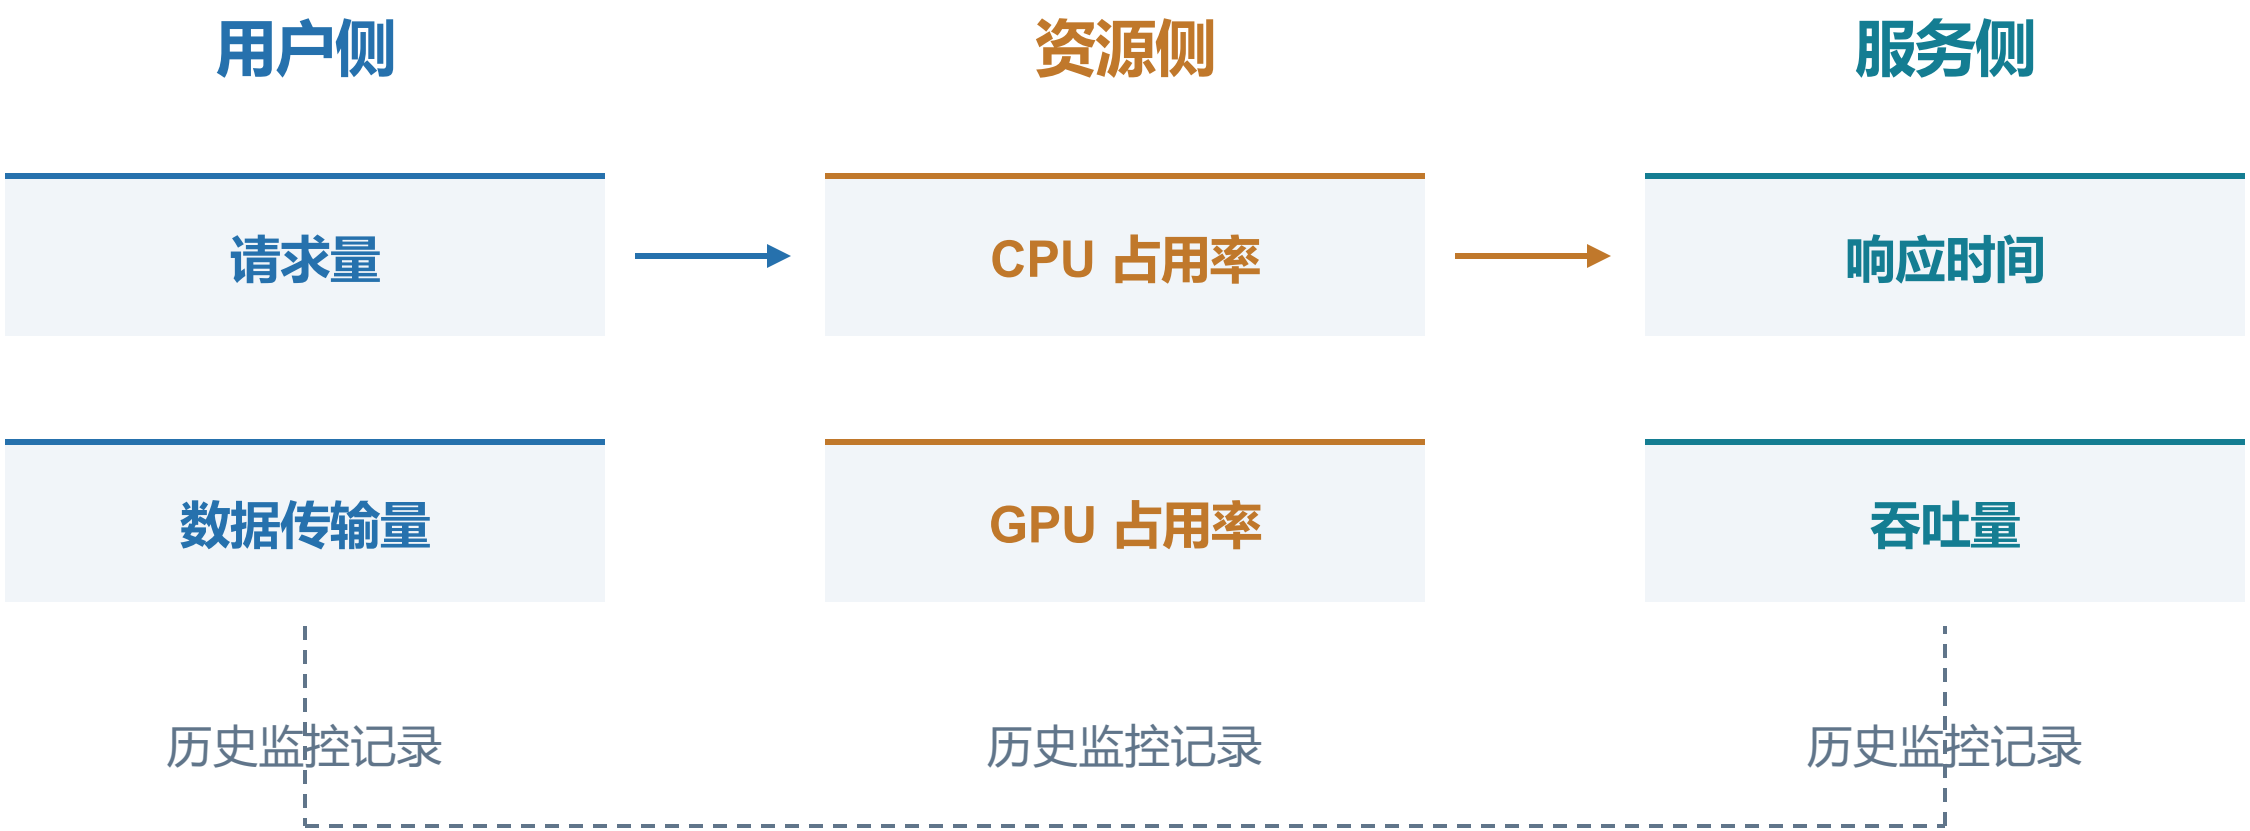
区域间交换信息，区域内补充特征，跨视图保留有效部分。

CausalScaler 要解决什么？ 云服务怎么提前扩缩容

把问题拆开	以线上服务接到一波请求为例
场景	请求有时突然增多。资源给少了，服务可能变慢。给多了，资源会闲置。
手头有什么	系统内部运行细节有限。可读到请求量、CPU 占用率、响应时间等监控记录。
要交什么	预测未来指标的可能取值，再决定何时加减资源、该配多少。
难在哪里	多个指标会一起变。提前备资源、避免闲置和减少频繁调整要一起考虑。

先看监控场景与时间曲线，再分析关系怎样支撑资源动作。

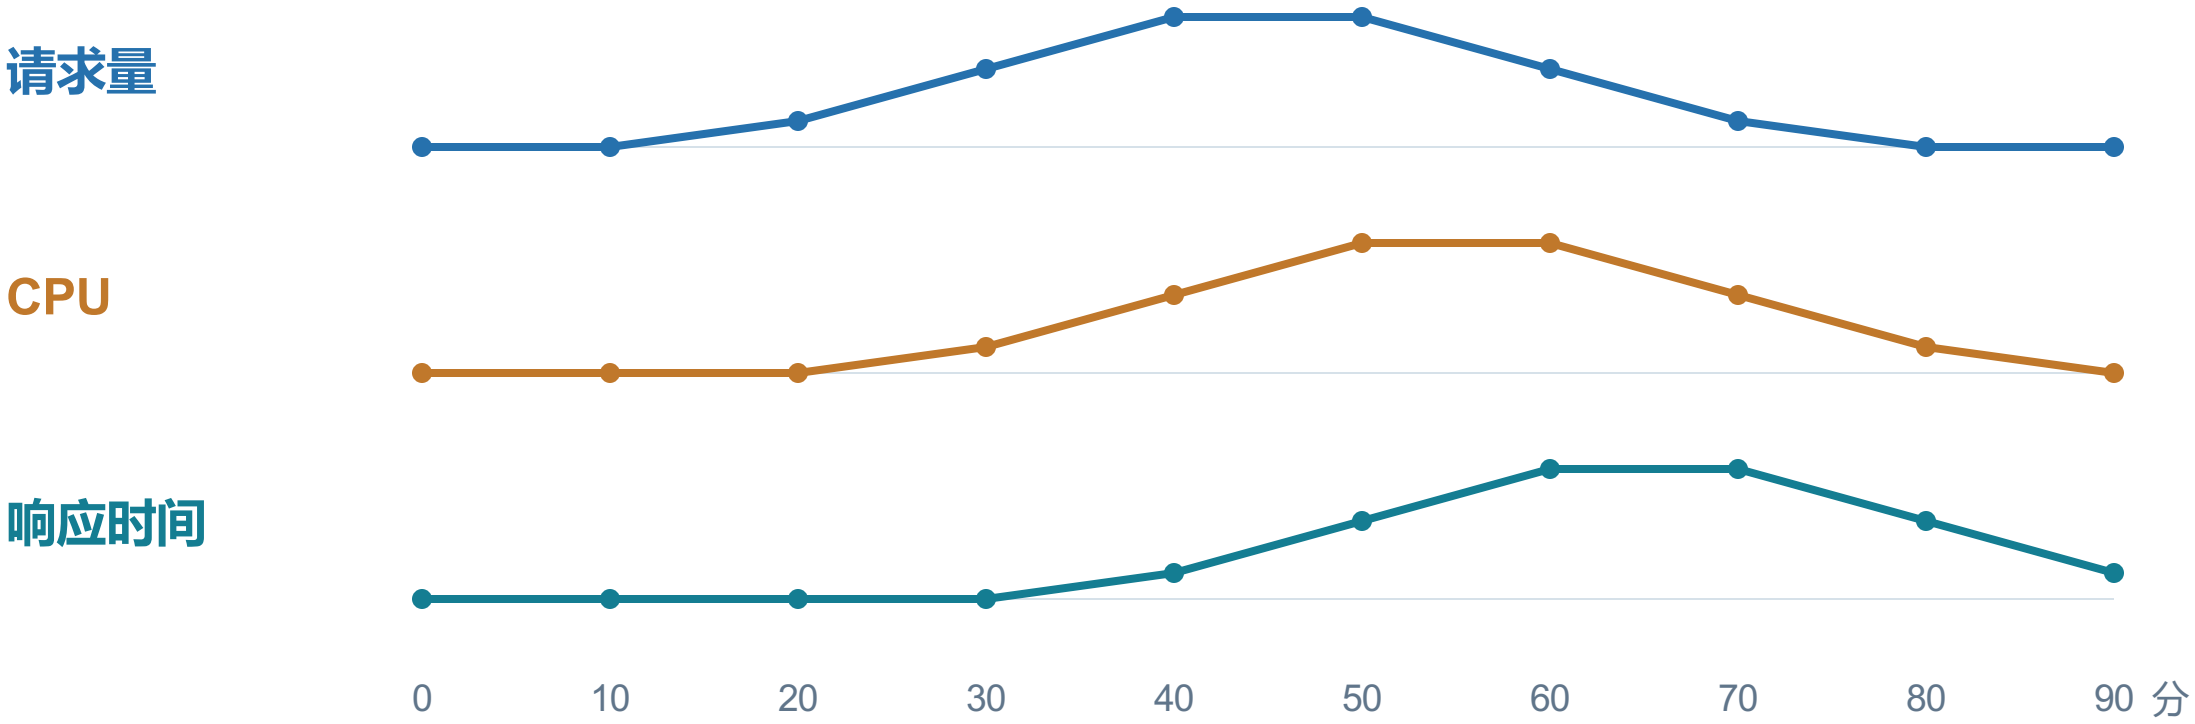
场景 用户、资源、服务各有自己的监控指标



分析对象是多层监控指标及其时间变化。箭头表示待分析的候选路径。

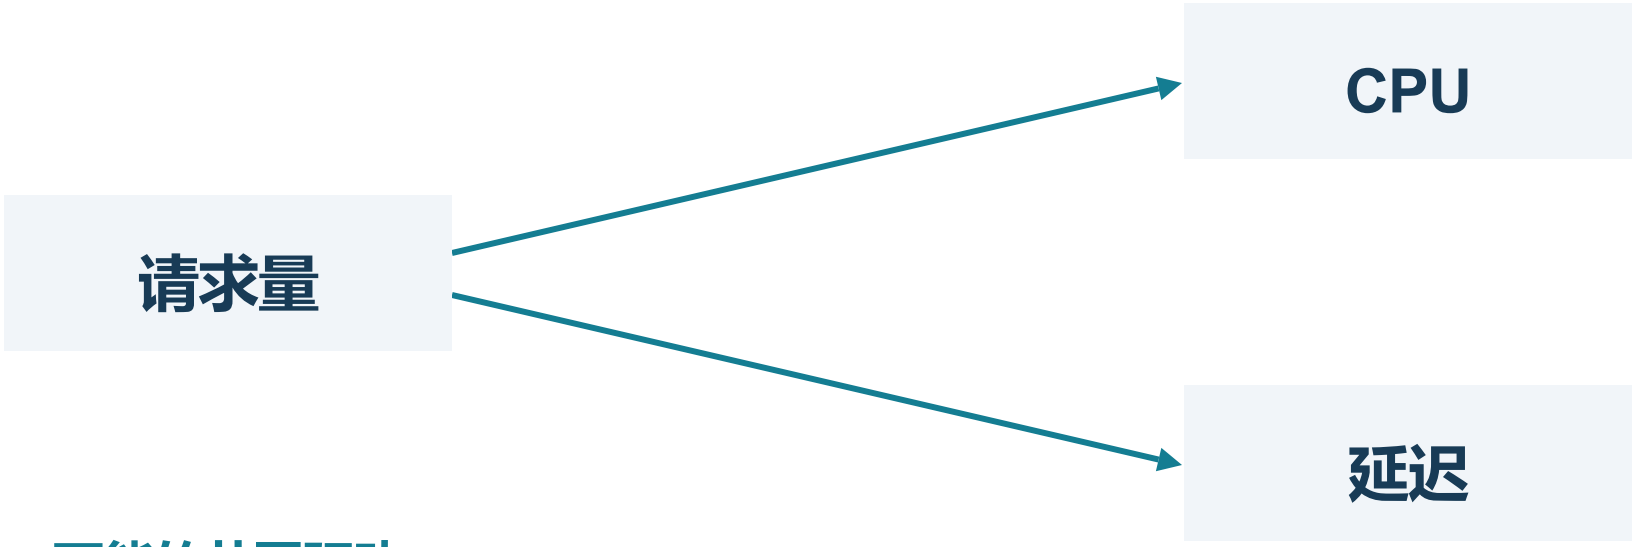
观察教学曲线 各指标的变化节奏和响应时间不同

各指标自身的相对尺度 · 构造曲线



先看各自的时间规律，再提出跨指标的先后关系候选。

请求量能同时推高 CPU 与延迟



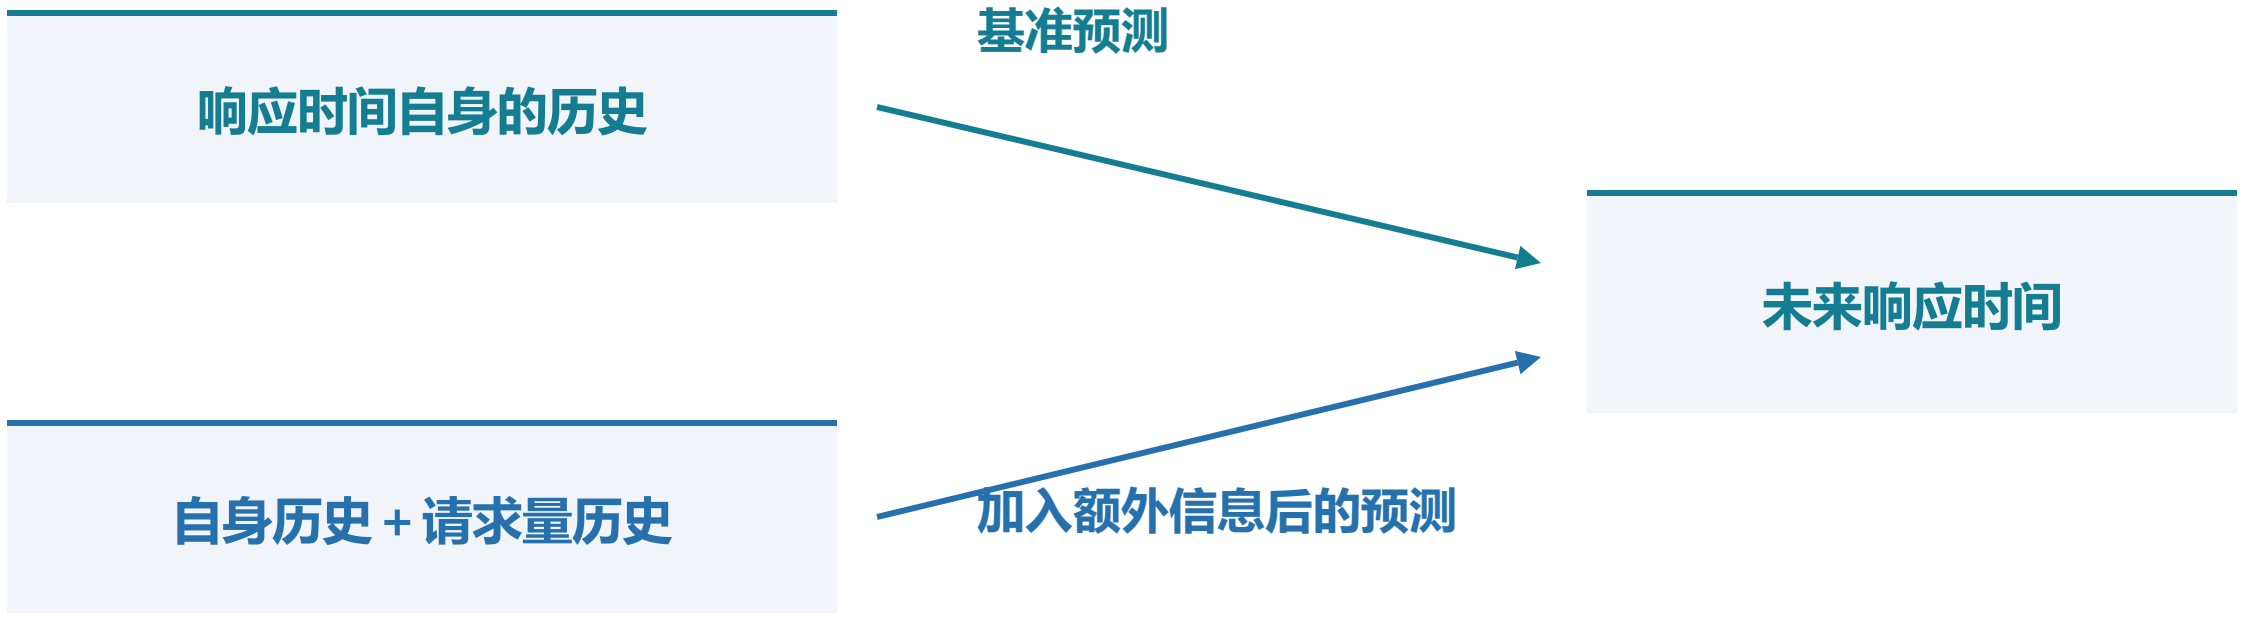
可能的共同驱动

从指标同升提出候选关系

问：如果增加 CPU 容量，延迟会怎样变？需要额外的证据。

方向怎样判断 多看一项历史，预测能增加多少信息

预测同一目标的同一个未来时刻



交换目标和历史来源，需要重新计算。

比较加入另一指标历史后的预测增益，由此定义有向关系。

CSI 因果强度指数 加入一项历史有多少帮助?

预测同一个结果	教学概率	读法
只看延迟自己的历史	25%	下一时刻出现高延迟的概率
再看请求量历史	50%	对同一个结果，概率变为原来的两倍

一次结果贡献 $\log_2(50\%/25\%) = 1$ bit。CSI 按历史和结果求加权平均。

挖掘结果 从成对比较得到有向依赖矩阵

行提供历史，列是预测目标

	请求量	CPU	响应时间
请求量	—	0.8	0.4
CPU	0.1	—	0.6
响应时间	0.05	0.2	—

请求量 → CPU

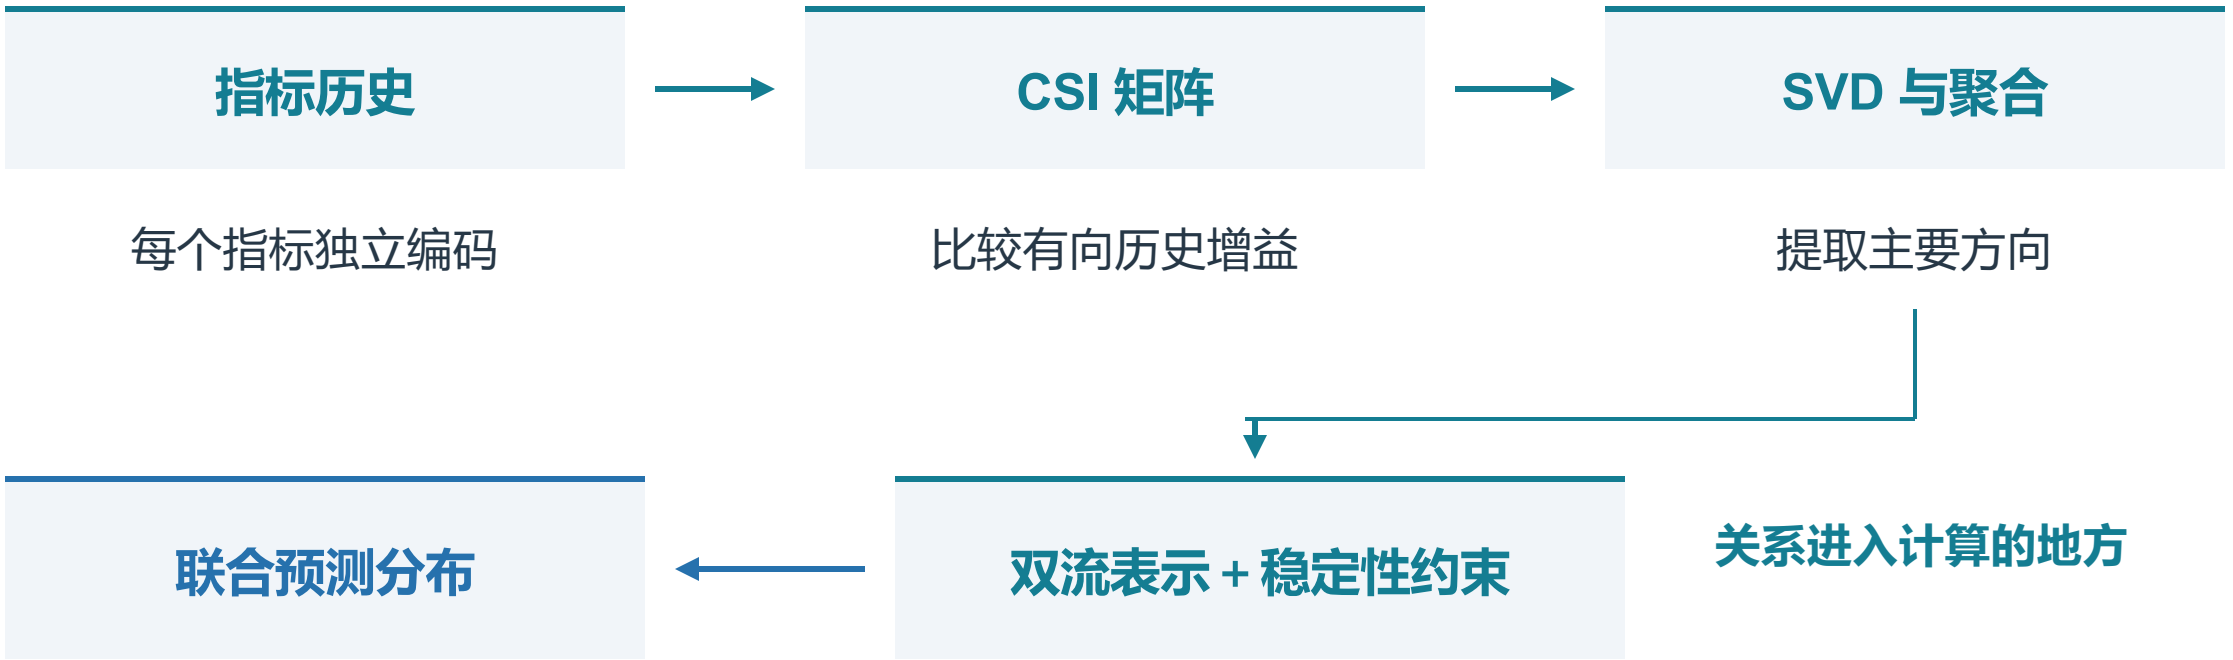
0.8 bit

CPU → 请求量

0.1 bit

成对比较形成关系矩阵。所有数值为教学构造，方向交换后可以不同。

怎样利用 指标关系先改变预测输入的组织



SVD 为奇异值分解，用来提取矩阵主要方向。随后学习稳定的预测表示。

双流模型 改一下干扰成分，看预测稳不稳

01

先按指标关系组织输入

用 CSI 建依赖矩阵
用 SVD 归纳主要方向

02

训练中打乱一部分

扰动模型内部表示
主干信息继续参与预测

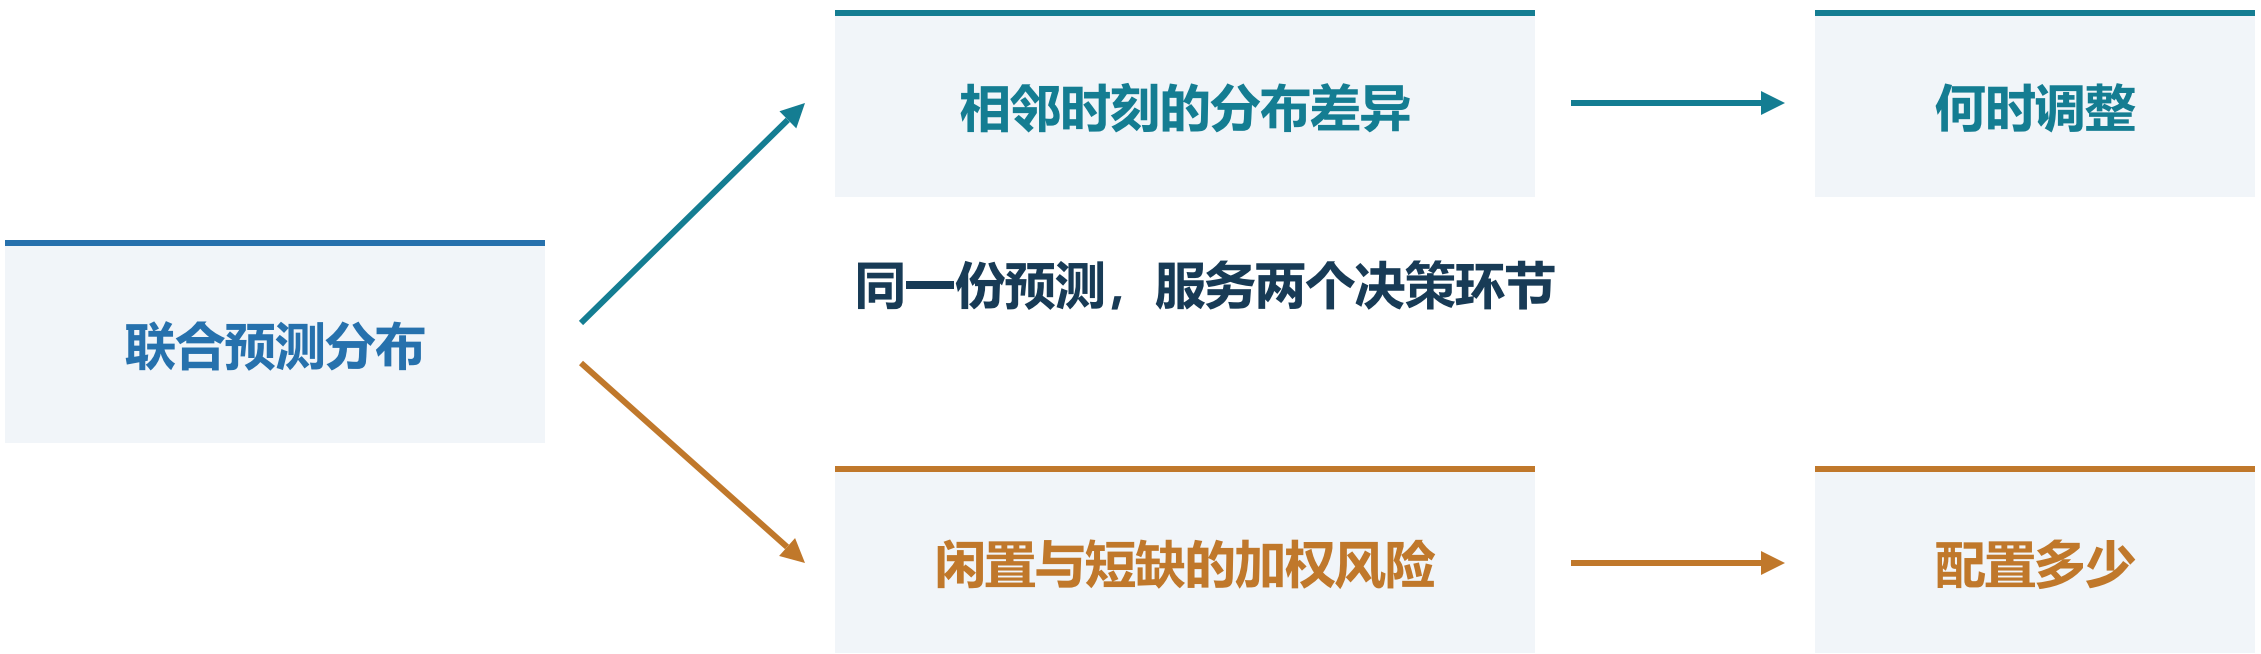
03

检查预测分布

惩罚扰动前后差得太大
保留稳定的预测信号

这一步发生在训练里。下一步才把预测分布交给扩缩容策略。

怎样利用预测 分布变化管频率，风险权重管配置



时序依赖改善预测信息，预测分布再进入明确的资源决策目标。

扩缩容决策要同时考虑波动和容量

选调整频率

比较相邻时刻的预测分布差异

差异大时频繁更新，差异小时沿用一次配置

枚举配置

$C(W) = w_{idle} \times P(\text{闲置}) + w_{short} \times P(\text{短缺})$

W 是资源单元数，两项权重体现资源与服务目标

下发配置

W^* = 使 $C(W)$ 最小的候选 W

不同风险权重可能得到不同配置

用预测分布做一次扩容选择

候选容量	闲置概率	短缺概率	短缺按 3 倍罚时
3	40%	30%	0.4 + 3×0.3 = 1.3
4	70%	10%	0.7 + 3×0.1 = 1.0

10 个等概率需求值为 2、2、2、2、3、3、3、4、4、5。容量 4 的代价较低。

离线预测与线上策略分别回答两个问题

证据	怎么测	可回答的问题
离线预测	四个数据集，MSE 与 CRPS	点预测及概率预测是否更准
线上 A/B	支付云平台一个月，统计资源及成功率	执行策略后的资源和服务表现

线上表格要把成功率和资源量一起读

策略	CPU 小时 ↓	GPU 小时 ↓	成功率 ↑
不扩缩容	10.20 M	1.130 M	100.00%
FIRM	3.72 M	0.409 M	99.23%
FSA	3.10 M	0.354 M	95.87%
CausalScaler	2.89 M	0.321 M	99.90%

成本与服务质量一起比较，并说清每个结论采用的基线。

CausalScaler 回看 有向时序依赖服务预测和动作

观察

多层指标各有规律，跨指标关系有方向，也可能有共同驱动。

关系输出

从条件历史比较得到有向依赖矩阵，再形成聚合表示。

任务用途

增强联合分布预测，以预测比较调整频率和资源风险。

三篇论文 关系不同，利用关系的方式也不同

案例	关系对象	挖掘产物	怎样利用	检验什么
MetaSTC	路段属性、车速	相似道路簇	分组任务与适配	聚类/适配消融
MAST	事件、气象	多源图与表征	传播、融合、筛选	分区误差/消融
CausalScaler	多层指标历史	有向时序矩阵	联合预测、扩缩容	预测/线上试验

相似模式、多源关系、有向时序依赖，分别进入后续任务的不同环节。

离堂判断 给问题选输出和验证方法

问题	输出	怎样验证
上游堵后下游是否也堵?	有方向和时延的规则	固定分母，在后续时段复算
下游十分钟后有多少流量?	未来流量的点估计或分布	用时间外样本测预测误差
调整配时能降低拥堵吗?	不同干预策略下的结果差异	做策略试验，或明确识别假设

参考文献 规则与模式方法

经典方法

Apriori（VLDB 1994） · PrefixSpan（ICDE 2001） · DTW（1978）
空间共位（TKDE 2004） · Joinless（TKDE 2006） · STS-Miner（TKDE 2008）

延伸阅读

Soft-DTW（ICML 2017） · Hopper（AAAI 2024） · 城市功能区共位（2024）
CSTS（2023） · 区域拥堵传播模式（2025 在线，2026 卷期）

参考文献 三篇研究案例

MetaSTC · ICDM 2024

A Backbone Agnostic Spatio-Temporal Framework for Traffic Forecasting
DOI 10.1109/ICDM59182.2024.00112

MAST · ICDM 2023

Meteorology-Assisted Spatio-Temporal Graph Network
for Uncivilized Urban Event Prediction · DOI 10.1109/ICDM58522.2023.00056

CausalScaler · DASFAA 2025

A Causality-Driven Autoscaling Framework for the Cloud
DOI 10.1007/978-981-95-4149-2_32